

Desarrollo de un modelo de pronóstico de precipitación para la región Bocacosta de Guatemala mediante redes neuronales LSTM

Miguel Alexander Avila Chacón

Universidad de San Carlos de Guatemala
Escuela de Ciencias Físicas y Matemáticas
Departamento de Física

Informe final de ejercicio profesional supervisado

Supervisado por
Ing. Klaus Hermann Aldo Johannes Zúñiga Kaufmann
Dr. Giovanni Ramírez

Guatemala, junio de 2026

Resumen

Aquí va el resumen del trabajo. Este formato reproduce una presentación más sobria, con márgenes amplios, texto centrado en una columna y una primera página similar a un manuscrito académico.

Palabras clave: precipitación; Bocacosta; Guatemala; redes neuronales LSTM; pronóstico climático.

1 Introducción

El ser humano se caracteriza por la búsqueda constante de herramientas que mejoren sus condiciones de vida. En los últimos años, estos esfuerzos se han orientado hacia la construcción de máquinas con algoritmos capaces de resolver, de forma automática y rápida, operaciones que resultan tediosas para una persona. Sin embargo, estas máquinas, basadas en algoritmos específicos, presentan una limitación importante: en ocasiones el problema que se busca resolver no requiere un tratamiento algorítmico sino el aprendizaje de patrones a través de la experiencia.

El ser humano es capaz de resolver múltiples problemas que no pueden expresarse mediante un algoritmo gracias a su experiencia y a su capacidad para memorizar y asociar hechos. Así, parece lógico que una forma de aproximarse a este tipo de problemas consista en construir sistemas capaces de reproducir dicha característica humana. En este sentido, las redes neuronales constituyen un intento simplificado de simular el funcionamiento del cerebro humano en el tratamiento de la información, cuya unidad básica de procesamiento se inspira en la célula fundamental del sistema nervioso: la neurona.

Una característica esencial del cerebro humano es su capacidad de aprendizaje, entendida como la habilidad de resolver problemas que inicialmente no podían abordarse, mediante la adquisición de nueva información sobre ellos [1, 2, 3, 4].

Por lo tanto, las redes neuronales se componen de unidades de procesamiento que intercambian datos o información. Se utilizan para reconocer patrones en conjuntos de datos, como imágenes, manuscritos o secuencias temporales, con el objetivo de aprender de ellos y mejorar su desempeño [1].

Debido a sus fundamentos, las redes neuronales artificiales presentan un gran número de características semejantes a las del cerebro, y por ello una gran cantidad de ventajas por sobre los programas basados en algoritmos [5]. Por ejemplo, son capaces de aprender a través de la experiencia, de generalizar de una gran serie de casos específicos a nuevos casos, de abstraer características esenciales de bancos de información, desechando la información irrelevante, etc.

2 Objetivos

2.1 General

Desarrollar un modelo predictivo de precipitación para la región de Bocacosta en Guatemala utilizando redes neuronales LSTM. Con datos históricos con el propósito de complementar los métodos tradicionales de pronóstico climático.

2.2 Específicos

1. Analizar series de tiempo de variables climáticas, como precipitación y temperatura, utilizando estadística descriptiva.
2. Diseñar e implementar un modelo LSTM utilizando datos históricos del INSIVUMEH.
3. Evaluar el desempeño del modelo mediante métricas de validación, como el análisis de correlación.
4. Comparar los resultados obtenidos con métodos tradicionales.

3 Marco teórico

3.1 Dinámica de la atmósfera

3.1.1 Conceptos básicos del sistema climático

El sistema climático terrestre es un sistema acoplado no lineal compuesto por la atmósfera, la hidrosfera, la criosfera, la litosfera y la biosfera. Su dinámica está gobernada por las leyes de conservación de la masa, el momento y la energía, así como por la ecuación de estado de los gases ideales. La fuente primaria de energía es la radiación solar de onda corta, la cual es distribuida de manera desigual sobre la superficie terrestre debido a la redondez del planeta y la inclinación del eje de rotación. Este desequilibrio radiativo genera gradientes de temperatura que impulsan la circulación general de la atmósfera y los océanos, cuyo objetivo termodinámico es transportar calor desde las regiones ecuatoriales hacia los polos.

3.1.2 Variables atmosféricas relevantes

Para caracterizar el estado de la atmósfera y su evolución, se utilizan variables de estado fundamentales. *La presión atmosférica* (P), definida como la fuerza por unidad de área ejercida por el peso de la columna de aire, decrece exponencialmente con la altura siguiendo la ecuación hipsométrica. *La temperatura* (T) es una medida de la energía cinética media de las moléculas del aire. *El contenido de vapor de agua*, que se cuantifica mediante la humedad específica (q), que representa la masa de vapor de agua por unidad de masa de aire húmedo, o la humedad relativa (HR) o (z), que indica el grado de saturación del aire respecto a la presión de vapor de saturación. *La velocidad del viento*, un campo vectorial $\vec{V} = (u, v, w)$, describe el movimiento del aire en las direcciones zonal, meridional y vertical, respectivamente [6, 7, 8].

3.1.3 Procesos termodinámicos

Los procesos adiabáticos son centrales en la formación de nubes y precipitación. Cuando una parcela de aire asciende en la atmósfera, encuentra una presión ambiental menor y se expande. Si el ascenso es lo suficientemente rápido para que el intercambio de calor con el entorno sea despreciable (proceso adiabático), la parcela se enfría a la tasa adiabática seca ($\Gamma_d \approx 9.8 \text{ K km}^{-1}$). Una vez que la parcela alcanza la saturación, la condensación libera calor latente, reduciendo la tasa de enfriamiento a una tasa pseudo-adiabática húmeda (Γ_s), cuyo valor varía con la temperatura y la presión, siendo típicamente de $4 - 6 \text{ K km}^{-1}$ en la troposfera tropical. Este calor latente es una fuente crucial de energía para la convección profunda [9, 10, 11].

3.2 Mecanismos de formación de la precipitación

3.2.1 Saturación, condensación y formación de nubes

La precipitación es el resultado final de una cadena de procesos microfísicos que comienzan con la saturación del aire. La ecuación de Clausius-Clapeyron establece la relación termodinámica fundamental entre la presión de vapor de saturación (P) y la temperatura:

$$\frac{dP}{dT} = \frac{L_v P}{R_v T^2} \quad (3.1)$$

donde L_v es el calor latente de vaporización y R_v es la constante específica del vapor de agua. Esta ecuación implica que la capacidad del aire para contener vapor de agua aumenta exponencialmente con la temperatura. En un clima más cálido, la atmósfera puede retener más humedad, lo que intensifica los eventos extremos de precipitación si los mecanismos de ascenso están presentes. La condensación del vapor sobre núcleos de condensación de nubes (CCN) da lugar a las gotitas de nube, cuyo tamaño es insuficiente para precipitar por gravedad [12, 13].

3.2.2 Procesos de colisión-coalescencia y Bergeron-Findeisen

La formación de gotas de lluvia requiere el crecimiento de las partículas de condensación de nube hasta alcanzar un tamaño crítico. En nubes cálidas (temperatura $> 0^\circ\text{C}$), predomina el proceso de **colisión-coalescencia**, donde gotas de diferente tamaño y velocidad terminal colisionan y se fusionan. En nubes frías o mixtas, opera el **proceso de Bergeron-Findeisen**, relacionada con la diferencia de presión de vapor de saturación sobre el agua líquida y el hielo. En un ambiente mixto saturado respecto al agua, existe sobresaturación respecto al hielo, lo que induce la deposición de vapor sobre los cristales de hielo a expensas de las partículas subfundidas [14].

3.2.3 Ascenso de masas de aire

Para que se produzca precipitación significativa, es indispensable el ascenso de masas de aire húmedo que enfríen la parcela hasta la saturación [15, 16, 17]. Los mecanismos de ascenso principales son:

- **Convección libre:** Calentamiento diferencial de la superficie que genera burbujas de aire cálido menos denso que ascienden [15, 18, 16].
- **Ascenso orográfico:** El viento horizontal se aproxima a una barrera montañosa y es forzado a elevarse, enfriándose adiabáticamente. Este mecanismo es crítico en la Bocacosta guatemalteca [15, 19, 20, 21].

- **Convergencia en niveles bajos:** La fricción superficial o la dinámica de ondas del este generan zonas de acumulación de masa que fuerzan el movimiento vertical ascendente [15, 16, 22].
- **Ascenso frontal:** Superficies de discontinuidad entre masas de aire de distinta densidad generan mecanismos de ascenso [15, 17].

3.3 Variables físicas relevantes para la predicción de precipitación local

La selección de predictores (características de entrada) para un modelo de precipitación debe basarse en su conexión causal con los procesos de condensación y ascenso.

3.3.1 Temperatura superficial del mar (SST)

La SST es la variable oceánica más influyente en el clima tropical. Anomalías cálidas en la SST incrementan el flujo de calor latente y sensible hacia la atmósfera, reduciendo la estabilidad estática e incrementando la humedad en la capa límite. En el contexto del Pacífico Oriental, la SST modula la intensidad de la Zona de Convergencia Intertropical (ZCIT) y la convección asociada a ondas del este [23, 24, 25].

3.3.2 Humedad relativa y específica

La humedad específica (q) en niveles medios (500 hPa) es un indicador directo de la materia prima disponible para la convección. La humedad relativa (HR) proporciona información sobre qué tan cerca de la saturación se encuentra una columna atmosférica, siendo crucial para activar la convección [26, 27, 28, 29].

3.3.3 Viento (componentes zonal y meridional)

El viento zonal (u) en niveles bajos (850 hPa) es fundamental para el transporte de humedad desde las fuentes oceánicas (el Jet de Bajo Nivel del Caribe o el flujo del Pacífico). La componente meridional (v) está asociada a la convergencia/divergencia y a la posición de la ZCIT. La cizalladura vertical del viento puede tanto inhibir como organizar los sistemas convectivos [15, 30, 31, 32, 33].

3.3.4 Geopotencial

La altura geopotencial (Z) en niveles de 500 hPa permite identificar la presencia de vaguadas y dorsales en la tropósfera media. Una vaguada profunda sobre Centroamérica se asocia con ascenso de gran escala y enfriamiento en la tropósfera superior, lo que desestabiliza la columna atmosférica y favorece tormentas [15, 34].

3.3.5 Teleconexiones climáticas (ENSO, AMO, TNA)

El sistema climático presenta modos de variabilidad de baja frecuencia que modulan las condiciones medias de precipitación en Guatemala.

- **ENSO (El Niño-Southern Oscillation):** La fase cálida (El Niño) se asocia típicamente con déficit de precipitación en la vertiente del Pacífico guatemalteco debido al debilitamiento de los vientos alisios y al desplazamiento de la convección profunda hacia el Pacífico Central. La fase fría (La Niña) se correlaciona con excesos de lluvia [34, 35, 36, 37].
- **AMO (Atlantic Multidecadal Oscillation):** Afecta la SST del Atlántico Norte y modula la fuerza del transporte de humedad desde el Caribe hacia el Pacífico a través del istmo [38, 39].
- **TNA (Tropical North Atlantic Index):** Anomalías cálidas en el Atlántico tropical intensifican la corriente de humedad hacia Centroamérica, compitiendo con la influencia del Pacífico [40, 41].

Todos estos indicadores se encuentran codificados en la evolución de la temperatura superficial del mar (SST).

3.3.6 Presión atmosférica en la superficie

Refleja directamente la dinámica de los sistemas meteorológicos en niveles bajos, donde se inician muchos de los procesos que conducen al ascenso de aire. Las zonas de baja presión suelen estar asociadas con convergencia, ascenso y desarrollo de nubosidad, mientras que los gradientes de presión determinan la intensidad y dirección del viento, influyendo en la organización del flujo atmosférico. Además, las variaciones temporales de la presión permiten identificar el desarrollo o debilitamiento de estos sistemas, aportando información sobre la evolución de los eventos de lluvia [15, 42, 43, 44].

3.3.7 Oscilación Madden-Julian (MJO)

Relevante en la precipitación guatemalteca (especialmente en el sur del país), porque representa una variabilidad organizada de la convección tropical que se propaga a lo largo del planeta, modulando la distribución espacial y temporal de las lluvias. A través de las fases de la onda, se activan regiones de convección activa y suprimida, afectando la circulación atmosférica, los patrones de viento y la disponibilidad de humedad [45, 46, 47].

3.3.8 Precipitación global

La precipitación entendida como el campo espacial a una escala planetaria, aporta información clave porque encapsula la organización espacial de los sistemas convectivos y sinópticos, así como la interacción entre diferentes escalas de movimiento atmosférico. Esta variable codifica patrones de bandas de convección, zonas de convergencia o sistemas que evolucionan y se desplazan en el tiempo y espacio.

3.4 Series de tiempo en climatología

3.4.1 Definición y componentes

Una serie de tiempo climática es una secuencia de observaciones de una variable atmosférica ordenada cronológicamente y generalmente equiespaciada. Matemáticamente, se define como $\{X_t : t \in T\}$, donde T es el índice temporal. Estas series suelen descomponerse en tres componentes aditivos o multiplicativos:

$$X_t = T_t + S_t + R_t \quad (3.2)$$

donde T_t es la tendencia a largo plazo (cambio climático o variabilidad decadal), S_t es la estacionalidad periódica (ciclo anual marcado por el monzón centroamericano), y R_t es el residuo o variabilidad de alta frecuencia (sinóptica e intradiurna).

3.4.2 Autocorrelación

La función de autocorrelación (ACF) mide la dependencia lineal entre los valores de la serie en el tiempo t y en rezagos $t - k$. En climatología, la precipitación exhibe una persistencia significativa; la lluvia de hoy está correlacionada con la lluvia de ayer, y más aún, con la humedad del suelo o los modos de variabilidad oceánica de semanas previas. Esta propiedad justifica el uso de modelos con memoria temporal como las redes recurrentes.

3.5 Relación entre procesos físicos y aprendizaje automático

3.5.1 Naturaleza no lineal del sistema climático

La atmósfera es un fluido geofísico turbulento gobernado por las ecuaciones no lineales de Navier-Stokes. Los procesos de retroalimentación, como el acoplamiento entre la radiación de onda larga y la nubosidad, o la liberación de calor latente en función de la convergencia de humedad, generan una respuesta altamente no lineal del sistema. Esta no linealidad implica que pequeños errores en las condiciones iniciales crecen exponencialmente (caos

determinista), limitando la predictibilidad de los modelos dinámicos más allá de unos pocos días para el detalle convectivo [48, 49, 50].

3.5.2 Limitaciones de modelos físicos tradicionales

Los Modelos de Circulación General (GCM) y los Modelos de Predicción Numérica del Tiempo (NWP) resuelven las ecuaciones primitivas en una malla discreta. Sin embargo, enfrentan dificultades inherentes en regiones de terreno complejo como la Bocacosta, donde la resolución espacial es insuficiente para resolver la orografía escarpada y los procesos de convección sub-malla deben ser parametrizados (aproximados empíricamente). Estas parametrizaciones introducen sesgos sistemáticos y errores en el pronóstico de precipitación orográfica.

3.5.3 Justificación del uso de Machine Learning

El Aprendizaje Automático (ML), y en particular las redes neuronales profundas, ofrecen un enfoque complementario puramente basado en datos. Una red neuronal puede aprender empíricamente la función de mapeo $f : \mathbb{R}^n \rightarrow \mathbb{R}$ que relaciona un conjunto de predictores físicos de gran escala (resueltos por reanálisis) con la precipitación local observada. Este enfoque permite capturar relaciones estadísticas no lineales y dependencias temporales complejas que son difíciles de formular explícitamente en un modelo físico.

3.5.4 Interpretabilidad física de los predictores

Si bien las redes neuronales son a menudo criticadas como *cajas negras*, la selección cuidadosa de predictores basada en la dinámica atmosférica permite **interpretabilidad física**, asegurando que la red está utilizando información sobre la SST del Pacífico, la humedad transportada por el viento zonal y la estabilidad atmosférica para inferir la probabilidad e intensidad de la precipitación, en concordancia con la teoría de la convección.

3.6 Redes neuronales artificiales

3.6.1 Definición y modelo matemático

Una red neuronal artificial es un modelo computacional inspirado en el sistema nervioso biológico, compuesto por unidades de procesamiento interconectadas llamadas neuronas [2, 4]. Formalmente, una neurona artificial recibe un vector de entrada $\mathbf{x} = (x_1, x_2, \dots, x_n)$, calcula una suma ponderada de estas entradas y aplica una función de activación no lineal $g(\cdot)$:

$$y = g\left(\sum_{i=1}^n w_i x_i + b\right) = g(\mathbf{w}^T \mathbf{x} + b) \quad (3.3)$$

donde $\mathbf{w}$ son los pesos sinápticos (parámetros ajustables que determinan la importancia de cada entrada) y b es el sesgo o *bias* [51].

3.6.2 Funciones de activación

La no linealidad $g(\cdot)$ es esencial para que la red pueda aproximar funciones complejas. Las funciones más comunes en modelos LSTM son:

- **Sigmoide** (σ): $\sigma(x) = \frac{1}{1+e^{-x}}$. Comprime los valores al rango $(0, 1)$, utilizada en puertas de control de flujo de información.
- **Tangente hiperbólica** ($\tanh$): $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$. Comprime valores al rango $(-1, 1)$, centrada en cero, utilizada para regular el estado de la celda.
- **ReLU (Rectified Linear Unit)**: $ReLU(x) = \max(0, x)$. Popular en capas ocultas densas por su eficiencia computacional y mitigación del desvanecimiento del gradiente.

3.7 Redes Neuronales Recurrentes (RNN)

3.7.1 Concepto de memoria temporal

Las redes neuronales *feedforward* estándar asumen independencia entre muestras, lo cual es inadecuado para series de tiempo donde X_t depende de X_{t-1} . Las Redes Neuronales Recurrentes (RNN) introducen conexiones de retroalimentación que forman un ciclo dirigido, permitiendo que la información persista [52]. El estado oculto $\mathbf{h}_t$ actúa como una *memoria* que resume la historia pasada de la secuencia:

$$\mathbf{h}_t = g(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h) \quad (3.4)$$

donde $\mathbf{W}_{hh}$ es la matriz de pesos recurrente que propaga el estado anterior.

3.7.2 Problema del Gradiente Evanesciente

El entrenamiento de RNNs mediante retropropagación a través del tiempo (BPTT) implica el cálculo de gradientes a través de múltiples pasos temporales. Debido a multiplicaciones repetidas de la matriz $\mathbf{W}_{hh}$ y las derivadas de las funciones de activación, los gradientes tienden a **desvanecerse** (tender a cero) o **explotar** (tender a infinito) a medida que los pasos de tiempo aumentan. En el contexto climático, donde la precipitación actual puede estar influenciada por la SST de varios meses atrás (teleconexiones ENSO), la RNN simple es incapaz de capturar estas dependencias de **largo plazo** debido al gradiente evanescente [53].

3.8 Redes LSTM (Long Short-Term Memory)

3.8.1 Justificación de su uso

La arquitectura LSTM fue diseñada específicamente para superar el problema del gradiente evanescente y aprender dependencias temporales de largo alcance. Dado que los fenómenos atmosféricos operan en múltiples escalas temporales (desde pequeños cambios locales en la altura geopotencial a una presión específica hasta la oscilación interanual del ENSO), la LSTM es la elección óptima para modelar la precipitación acumulada. Su capacidad para recordar y olvidar información selectivamente permite a la red mantener un estado que refleje la condición climática de fondo (fase de La Niña, Niño o Neutro) mientras reacciona a perturbaciones sinópticas de corta duración [54, 55].

3.8.2 Arquitectura interna y ecuaciones fundamentales

La celda LSTM reemplaza la neurona recurrente simple por un módulo que contiene una **celda de estado** (C_t) y tres compuertas que regulan el flujo de información [54].

1. **Puerta de olvido (f_t):** Decide qué información eliminar del estado de la celda previo C_{t-1} . Observa $\mathbf{h}_{t-1}$ y $\mathbf{x}_t$, y emite un valor entre 0 (olvidar) y 1 (retener).

$$f_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (3.5)$$

2. **Puerta de entrada (i_t) y candidato de celda ($\tilde{C}_t$):** Decide qué nueva información almacenar en la celda. La puerta de entrada selecciona los valores a actualizar, mientras que una capa tanh genera un vector de nuevos valores candidatos.

$$i_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (3.6)$$

$$\tilde{C}_t = \tanh(\mathbf{W}_C \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \quad (3.7)$$

3. **Actualización del estado de celda (C_t):** El estado anterior se actualiza combinando la acción del olvido y la adición de la nueva información.

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (3.8)$$

El flujo lineal de gradiente a través de la operación $+$ y $*$ (producto elemento a elemento) evita el desvanecimiento del gradiente a lo largo de decenas de pasos temporales.

4. **Puerta de salida (o_t) y estado oculto (h_t):** La salida se basa en el estado de la celda, pero filtrado por una compuerta de salida que decide qué partes del estado

actual son relevantes para el siguiente paso o la predicción final.

$$o_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (3.9)$$

$$\mathbf{h}_t = o_t * \tanh(C_t) \quad (3.10)$$

3.9 Preprocesamiento de datos climáticos

3.9.1 Normalización y estandarización

Las variables climáticas poseen escalas y unidades físicas dispares (por ejemplo geopotencial en m^2s^{-2} , humedad relativa en %). Para que el optimizador por gradiente converja eficientemente y las funciones de activación operen en su rango sensible, es necesario escalar los datos. La estandarización se utiliza comúnmente en climatología para preservar las anomalías relativas:

$$X_{std} = \frac{X - \mu}{\sigma} \quad (3.11)$$

donde μ es la media y σ la desviación estándar del período de entrenamiento.

3.9.2 Manejo de datos faltantes

Los conjuntos de datos observacionales (pluviómetros) o satelitales contienen lagunas. Se aplican técnicas de imputación como la interpolación lineal temporal o la sustitución por la mediana climatológica del mes correspondiente. Para mantener la consistencia física, es preferible eliminar segmentos cortos de reanálisis en lugar de interpolar valores espurios de viento.

3.9.3 Construcción de ventanas temporales

Para alimentar la red LSTM, la serie de tiempo continua debe ser segmentada en secuencias de longitud fija L (ventanas de entrada bien definidas). Si se predice la precipitación en el tiempo t , la entrada es la matriz $\mathbf{X} \in \mathbb{R}^{L \times N}$ donde N es el número de predictores. La elección de L es crítica: debe ser lo suficientemente larga para capturar la evolución de una onda del este (3-5 días) y la memoria de la humedad del suelo, pero no tan larga como para diluir el gradiente en el entrenamiento.

3.9.4 División de datos

Para evaluar la capacidad de generalización del modelo, el conjunto de datos se divide en:

- **Entrenamiento:** Aproximadamente 70-80% de los datos (años iniciales o completamente aleatorios, por ejemplo). Usado para ajustar los pesos $\mathbf{W}$ y $\mathbf{b}$ mediante retropropagación.
- **Validación:** 30-20% de los datos. Usado para monitorear el rendimiento fuera de muestra y detener el entrenamiento (*early stopping*) antes del sobreajuste.
- **Prueba:** Un conjunto de datos auxiliar que proporcione una estimación insesgada del rendimiento operativo del modelo final.

3.10 Evaluación de modelos predictivos

La bondad del ajuste y la precisión del pronóstico se cuantifican mediante métricas de error y correlación.

3.10.1 RMSE (Raíz del error cuadrático medio)

Mide la desviación estándar de los residuos (errores de predicción). Penaliza fuertemente los errores grandes debido al término cuadrático (llegando a valores altos cuando se presentan eventos extremos). Es útil para cuantificar la magnitud media del error en las mismas unidades que la variable observada (mm/día) [56].

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3.12)$$

3.10.2 MAE (Error Absoluto Medio)

Mide la magnitud promedio de los errores en un conjunto de predicciones, sin considerar la dirección. Es menos sensible a valores atípicos extremos que el RMSE [56].

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3.13)$$

3.10.3 Correlación de Pearson (r)

Evalúa la relación lineal entre los valores predichos ($\hat{y}$) y los observados (y). Un valor cercano a 1 indica que el modelo captura correctamente la fase y la tendencia de la variabilidad de la precipitación, aunque pudiera tener un sesgo sistemático en la magnitud [57].

$$r = \frac{\sum (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum (y_i - \bar{y})^2 \sum (\hat{y}_i - \bar{\hat{y}})^2}} \quad (3.14)$$

3.10.4 Índice de eficiencia de Nash-Sutcliffe (NSE)

Índice ampliamente utilizado para evaluar la bondad de ajuste de un modelo hidrológico. Un valor de 1 indica una coincidencia perfecta entre el modelo y los datos observados. Un valor entre 0 y 1 indica valores aceptables, donde una mejor precisión se asocia a valores cercanos a 1. Un valor de NSE igual que cero indica que la capacidad predictiva del modelo es igual a la de la media de los datos observados. Y un valor negativo indica que la media es un mejor predictor que el modelo propuesto [58].

Se calcula como la relación entre la varianza del error del modelo y la varianza de los datos observados.

$$NSE = 1 - \frac{\sum_{t=1}^T (Q_0^t - Q_m^t)^2}{\sum_{t=1}^T (Q_0^t - \bar{Q}_0)^2}. \quad (3.15)$$

Donde Q_0 es el valor observado, Q_m el valor simulado y $\bar{Q}_0$ la media de los valores observados.

Es matemáticamente idéntico al cálculo del coeficiente de correlación, sin embargo, se diferencia de este por su interpretabilidad y rango, pues NSE puede ser cualquier número negativo.

Mientras que el coeficiente de correlación mide la linealidad y co-variación, el NSE mide la precisión del modelo .

3.10.5 Eficiencia de Kling-Gupta (KGE)

Es un indicador de la bondad de ajuste de un modelo, utilizado comúnmente en las ciencias hidrológicas. Creado con el objetivo de mejorar las métricas ampliamente utilizadas, como el coeficiente de determinación y el coeficiente de eficiencia de Nash-Sutcliffe. Un valor de 1 indica una coincidencia perfecta entre el modelo y los datos observados. Un valor entre $1 - \sqrt{2}$ y 1 indica valores aceptables, donde una mejor precisión se asocia a valores cercanos a 1. Un valor de NSE igual que $1 - \sqrt{2}$ indica que la capacidad predictiva del modelo es igual a la de la media de los datos observados. Y un valor menor a $1 - \sqrt{2}$ indica que la media es un mejor predictor que el modelo propuesto. Se define como:

$$KGE = 1 - \sqrt{(r - 1)^2 + (\alpha - 1)^2 + (\beta - 1)^2}. \quad (3.16)$$

Donde r es el coeficiente de correlación de Pearson, α representa la variabilidad de los errores de predicción, esto es, $\alpha = \sigma_s / \sigma_o$, donde σ_s^2 es la varianza de la serie temporal simulada y σ_o^2 es la varianza de la serie temporal observada. Finalmente β es el sesgo del modelo, entendido como $\beta = \mu_s / \mu_o$, siendo μ_s la media de los datos simulados y μ_o la media de los datos observados [59].

3.11 Problemas en el entrenamiento de modelos

3.11.1 Overfitting (sobreajuste)

Ocurre cuando el modelo aprende no solo la señal física subyacente, sino también el *ruido* estadístico y las idiosincrasias del conjunto de entrenamiento. Un modelo sobreajustado exhibe un error muy bajo en entrenamiento pero un error alto en validación/prueba. En el contexto de LSTM, el sobreajuste se manifiesta cuando la red memoriza secuencias específicas de años pasados en lugar de aprender las relaciones atmósfera-lluvia generalizables.

3.11.2 Underfitting (subajuste)

Sucede cuando el modelo es demasiado simple (pocas neuronas o capas) para capturar la complejidad no lineal del sistema climático. El error es alto tanto en entrenamiento como en validación, indicando que el modelo no ha logrado aprender la función de mapeo verdadera.

3.11.3 Técnicas de regularización

Para combatir el sobreajuste en redes LSTM profundas se emplean:

- **Dropout:** Durante el entrenamiento, se desactiva aleatoriamente un porcentaje p de las neuronas en cada paso (ignorando su salida y gradiente). Esto fuerza a la red a no depender de una ruta de activación específica, mejorando la robustez y actuando como un ensamble de sub-redes [60].
- **Early Stopping:** El entrenamiento se detiene cuando el error de validación deja de disminuir y comienza a aumentar, incluso si el error de entrenamiento sigue bajando. Es una de las técnicas más efectivas en series temporales climáticas [61].

3.12 Contexto climático de Guatemala y región de Bocacosta

3.12.1 Estacionalidad de la precipitación

La región Bocacosta se ubica en la vertiente sur de la cadena volcánica de Guatemala, descendiendo hacia la llanura costera del Pacífico. El régimen de precipitación es marcado y estacional, definido por el monzón de América del norte y la migración latitudinal de la Zona de Convergencia Intertropical. Como en el resto del país, la temporada lluviosa se extiende típicamente de mayo a octubre, presentando un doble máximo característico: un primer pico en junio asociado al inicio de la época lluviosa y al paso de ondas del este, una canícula en julio-agosto debido a la intensificación de los vientos alisios y subsidencia, y un segundo máximo en septiembre-octubre coincidiendo con el pico de actividad de la Zona

de Convergencia Intertropical en el Pacífico Oriental y la temporada de ciclones tropicales [19, 20].

3.12.2 Influencia del pacífico y rol de la orografía

La Bocacosta está directamente expuesta al flujo de humedad del Océano Pacífico tropical nororiental. La interacción entre el flujo de bajo nivel del suroeste y la pronunciada orografía de la Sierra Madre guatemalteca es el principal mecanismo forzante de la precipitación en la zona. El ascenso forzado (efecto Föhn) condensa la abundante humedad oceánica, generando núcleos de precipitación convectiva.

3.12.3 Importancia de la predicción en la región

La Bocacosta es una de las zonas con más producción agrícola del país (café, caña de azúcar, hule) [62, 63], pero también una de las más vulnerables a eventos hidrometeorológicos extremos. La predicción precisa de la precipitación a corto y mediano plazo es un insumo fundamental para:

- Sistemas de Alerta Temprana (SAT) ante deslizamientos y crecidas de ríos.
- Planificación de siembra y cosecha en el sector agrícola.
- Gestión de recursos hídricos para generación hidroeléctrica en la vertiente del Pacífico.

El desarrollo de un modelo LSTM para la precipitación local busca complementar las limitaciones de los modelos numéricos globales, proporcionando una herramienta basada en predictores físicos de gran escala.

4 Metodología

4.1 Diseño general del estudio

El modelo predictivo se construyó siguiendo un enfoque de aprendizaje automático basado en una arquitectura LSTM multi-torre, la cual procesa series temporales de predictores climáticos de múltiples variables y resoluciones espaciales para estimar la precipitación mensual acumulada (en mm) en una región de interés. El flujo de trabajo se estructura en cuatro etapas principales: (1) adquisición y preprocesamiento de datos, (2) normalización y reducción de dimensionalidad, (3) entrenamiento y validación del modelo, y (4) evaluación mediante diagnósticos completos.

4.2 Adquisición y preprocesamiento de datos

4.2.1 Fuentes de datos

Los datos de precipitación observada fueron obtenidos del Instituto Nacional de Sismología, Vulcanología, Meteorología e Hidrología (INSIVUMEH) de Guatemala, consistiendo en series de tiempo diarias de precipitación medida en estaciones pluviométricas calibradas distribuidas a lo largo del país. Los predictores climáticos fueron adquiridos de fuentes globales de reanálisis (Copernicus Climate Data Store: ERA5 post-processed daily statistics on single [and pressure] levels from 1940 to present) considerados en la cuadrícula de latitudes de $[-165, 0]$ en longitud y $[-15, 75]$ en latitud, para poder considerar las teleconexiones que dominan el escenario climático guatemalteco, sin considerar ruido proveniente de otras regiones climáticas lejos de Centroamérica:

- Temperatura Superficial del Mar (SST).
- Presión Superficial (SP).
- Humedad relativa y específica (r y q) a 500 hPa.
- Geopotencial (z) a 500 hPa.
- Velocidades zonal y meridional (u , v) a 850 hPa.
- Índices de Madden-Julian Oscillation (MJO) (RMM1, RMM2).
- Precipitación global (tp).

Se asume que determinadas combinaciones de predictores tendrán mejores resultados que otras, tanto para el país en general, como para regiones y departamentos específicos de este. Las combinaciones propuestas fueron:

1. SST, z, r, q, tp, u, v.
2. SST, SP, tp.
3. SST, SP, tp, MJO.
4. SST, tp, MJO.
5. SST, SP, z, r, q, tp, u, v.
6. SST, SP, z, r, q, tp, u, v, MJO.
7. SST, tp.

La efectividad de cada predictor será evaluada mediante diagnósticos descritos más adelante.

4.2.2 Normalización espacio-temporal

Todos los archivos de entrada (NetCDF4) fueron procesados para garantizar consistencia dimensional y nomenclatura:

- **Dimensiones:** Se normalizó la nomenclatura de ejes a (`time`, `lat`, `lon`), independientemente del esquema original del archivo (`T`, `valid_time`, `time_counter`, etc.).
- **Coordenadas:** Se identificaron automáticamente los nombres de latitud y longitud (`latitude`, `y`, `Y`) y se renombraron a `lat` y `lon`.
- **Indexación temporal:** Se convirtieron valores numéricos o cadenas de tiempo a formato `datetime64` de NumPy para facilitar operaciones de fecha y sincronización.

4.2.3 Detección de píxeles válidos y máscaras espaciales

Dado que las grillas rasterizadas típicamente contienen píxeles con NaN (océanos, regiones fuera de dominio), se construyó una máscara de validez mediante muestreo de los primeros 50 pasos temporales de cada predictor. Un píxel se clasificó como válido si presentaba al menos un valor finito en el intervalo muestreado. Esta máscara aseguró que:

- La red neuronal procesa solo píxeles con datos físicamente significativos.
- Se evita acumular gradientes en píxeles sin información.
- La compresión dimensional mediante PCA se realiza exclusivamente sobre píxeles válidos.

4.3 Normalización y reducción de dimensionalidad

4.3.1 Estandarización de predictores

Para que el optimizador por gradiente converja eficientemente, cada predictor fue estandarizado usando estadísticas (media μ_p y desviación estándar σ_p) calculadas sobre el conjunto de entrenamiento:

$$X_{\text{std}}^{(p)} = \frac{X^{(p)} - \mu_p}{\sigma_p} \quad (4.1)$$

donde p indexa cada uno de los n_{pred} predictores. Estas estadísticas se almacenaron en la metadata del entrenamiento para reproducibilidad y aplicación consistente en predicciones posteriores.

4.3.2 Análisis de Componentes Principales (PCA)

Como los predictores climáticos típicamente presentan elevada colinealidad espacial (continuidad suave de campos como temperatura y presión), se aplicó PCA para reducir la dimensionalidad:

1. Se calculó la matriz de covarianza de cada predictor estandarizado sobre el conjunto de entrenamiento en píxeles válidos.
2. Se seleccionaron las primeras k_p componentes principales que acumulaban al menos el 95% de la varianza explicada, siempre que fuera posible.
3. El modelo PCA se almacenó para transformación consistente durante predicción.

La reducción dimensional cumple varios objetivos:

- Disminuye el número de parámetros de la red neuronal, mitigando el sobreajuste.
- Comprime información correlacionada en componentes ortogonales.
- Acelera el cálculo durante entrenamiento y predicción.

4.4 Construcción y segmentación de secuencias temporales

4.4.1 Ventanas de entrada

Para la predicción de precipitación mensual, la red LSTM requiere una ventana de entrada de longitud fija L (por defecto, $L = 31$ días). Formalmente, si se predice la precipitación acumulada en el mes $[t_{\text{start}}, t_{\text{end}}]$, la secuencia de entrada comprende L días anteriores:

$$\mathbf{x}_{t-L:t} = [X_{t-L}, X_{t-L+1}, \dots, X_{t-1}] \quad (4.2)$$

donde cada X_τ es un vector de características (predictores normalizados y comprimidos por PCA) para el día τ .

4.4.2 División cronológica del conjunto de datos

Para evaluar la capacidad de generalización del modelo sin contaminación temporal (data leakage), el conjunto de datos se dividió de manera cronológica en dos subconjuntos:

- **Entrenamiento:** Años iniciales (80% del período total). Utilizado para ajustar los pesos $\mathbf{W}$ y sesgos $\mathbf{b}$ de la red mediante retropropagación del error.
- **Validación:** Período intermedio (20%). Monitorea el desempeño fuera de muestra durante el entrenamiento, permitiendo la detención temprana (*early stopping*) para evitar sobreajuste.

Esta partición respeta la estructura temporal inherente a los datos climáticos, donde la dependencia estadística es más fuerte entre observaciones cercanas en tiempo.

4.5 Arquitectura del modelo LSTM multi-torre

4.5.1 Diseño de entrada y torres paralelas

El modelo multi-torre procesa cada predictor climático mediante una rama (torre) independiente de capas LSTM y capas totalmente conectadas, explotando la especificidad de cada variable:

1. **Torre p :** Recibe una secuencia de entrada $\mathbf{x}_{t-L:t}^{(p)} \in \mathbb{R}^{L \times d_p}$, donde d_p es la dimensión post-PCA del predictor p .
2. **Capas LSTM:** La secuencia temporal se procesa mediante una o más capas LSTM que capturan dependencias de largo alcance. Cada LSTM emite un estado oculto $\mathbf{h}_T^{(p)}$ al final de la ventana.
3. **Capas densas locales:** El estado final se procesa mediante capas totalmente conectadas para extraer características no lineales específicas del predictor.

4.5.2 Fusión de representaciones y decodificación espacial

Las salidas de todas las torres se concatenan:

$$\mathbf{z} = [\mathbf{z}^{(1)}, \mathbf{z}^{(2)}, \dots, \mathbf{z}^{(n_{\text{pred}})}] \quad (4.3)$$

A continuación, se aplican varias técnicas de refinamiento espacial:

1. **Modulación por coordenadas:** Un módulo aprendible que ingiere las coordenadas geográficas (lat, lon) de cada píxel y genera factores de escala y desplazamiento (shift) para modular las predicciones. Esta técnica captura variabilidad geográfica implícita.
2. **Sesgo por píxel:** Se añade un sesgo aprendible específico de cada píxel, permitiendo que el modelo capture errores sistemáticos locales.
3. **Refinamiento espacial:** Un módulo convolucional (2D) que reconstruye temporalmente la grilla ($h_{\text{target}} \times w_{\text{target}}$) a partir de píxeles válidos, propaga información espacial mediante capas convolucionales (Conv2D + BatchNorm), y reextrae los píxeles tierra para corrección fina.

4.5.3 Transformación de objetivo

Debido a la distribución fuertemente asimétrica (sesgada) de la precipitación mensual, se aplicó una transformación invertible al objetivo antes del entrenamiento. Las opciones implementadas incluyen:

- **Log-transformación:** $y_{\text{trans}} = \log(y + 1)$, adecuada para datos con rango amplio.
- **Raíz cúbica:** $y_{\text{trans}} = y^{1/3}$, reduce el impacto de valores extremos manteniendo el orden.
- **Raíz cuarta:** $y_{\text{trans}} = y^{1/4}$, estabilización más fuerte.
- **Raíz cuadrada:** $y_{\text{trans}} = \sqrt{y}$, apropiada para datos con varianza proporcional a la media.
- **Estandarización:** $y_{\text{trans}} = \frac{y - \mu_y}{\sigma_y}$, para varianza homogénea.

El modelo LSTM entrenó en el espacio transformado, y las predicciones se invirtieron analíticamente para recuperar precipitación en milímetros.

4.6 Entrenamiento del modelo

4.6.1 Función de pérdida y optimizador

Se empleó el error cuadrático medio (MSE) como función de pérdida en el espacio transformado:

$$\mathcal{L} = \text{MSE}(y_{\text{trans}}, \hat{y}_{\text{trans}}) = \frac{1}{n} \sum_{i=1}^n (y_{\text{trans},i} - \hat{y}_{\text{trans},i})^2 \quad (4.4)$$

El modelo se optimizó usando Adam (Adaptive Moment Estimation) con un esquema de tasa de aprendizaje adaptativo: calentamiento lineal (warmup) durante los primeros pasos, seguido de decaimiento coseno con reinicios (cosine annealing with warm restarts). Este esquema equilibra convergencia rápida inicial con refinamiento fino tardío.

4.6.2 Regularización y detención temprana

Para mitigar sobreajuste en esta red profunda se aplicaron:

1. **Dropout:** Se desactivó aleatoriamente un porcentaje (típicamente 20-30%) de neuronas en cada paso durante entrenamiento, forzando redundancia y robustez.
2. **Batch Normalization:** Se normalizaron las activaciones por minilote, acelerando convergencia y mejorando generalización.
3. **Early Stopping:** El entrenamiento se detuvo cuando la métrica de validación (RMSE o KGE) no mejoró durante N épocas consecutivas (típicamente $N = 15$), previniendo descenso en generalización.

4.6.3 Acumulación de gradientes

Para facilitar el entrenamiento con lotes grandes (que mejora estabilidad del gradiente), se implementó acumulación de gradientes: cada paso acumula gradientes de múltiples minilotes (típicamente 4-8) antes de actualizar pesos. Esto efectivamente incrementa el tamaño del lote sin aumentar el uso de memoria GPU.

4.6.4 Función de Pérdida Compuesta y Argumentos de Entrenamiento

El modelo utiliza una función de pérdida compuesta que integra múltiples componentes diseñados para capturar diferentes aspectos del problema de predicción de precipitación. A continuación se describen las funciones de pérdida implementadas y los parámetros principales utilizados durante el entrenamiento.

Componentes de la Función de Pérdida

La pérdida total es una combinación ponderada de cuatro componentes principales:

$$\mathcal{L}_{\text{total}} = w_H \cdot \mathcal{L}_{\text{Huber}} + w_Q \cdot \mathcal{L}_{\text{Quantil}} + w_T \cdot \mathcal{L}_{\text{Tweedie}} + w_C \cdot \mathcal{L}_{\text{Correlación}} + \mathcal{L}_{\text{Suavizado}} \quad (4.5)$$

donde w_H , w_Q , w_T y w_C son los pesos relativos de cada componente, relacionados mediante:

$$w_H = 1.0 - w_Q - w_T - w_C \quad (4.6)$$

1. Pérdida de Huber Focal La función de Huber es robusta ante valores atípicos. Se define como:

$$\mathcal{L}_{\text{Huber}}(y, \hat{y}) = \begin{cases} \frac{1}{2}(y - \hat{y})^2 & \text{si } |y - \hat{y}| \leq \delta \\ \delta (|y - \hat{y}| - \frac{\delta}{2}) & \text{si } |y - \hat{y}| > \delta \end{cases} \quad (4.7)$$

El parámetro delta (`-huber_delta`) controla el punto de transición entre comportamiento cuadrático y lineal. La versión focal amplifica el error en eventos extremos mediante un factor w_{focal} que depende de la intensidad de precipitación:

$$w_{\text{focal}} = 1.0 + (\text{extreme_boost} - 1.0) \cdot \sigma \left(\frac{y_{\text{mm}} - h_{\text{high}}}{h_{\text{width}}} \right) \quad (4.8)$$

donde σ es la función sigmoide, h_{high} es el umbral superior en mm, y `-extreme_boost` controla la amplificación.

2. Pérdida de Cuantil Adaptativa La pérdida de cuantil se adapta según la intensidad de precipitación, utilizando tres regímenes:

$$\mathcal{L}_{\text{Quantil}} = \mathbb{E} [w_{\text{low}} \cdot \ell_{\tau=0.50} + w_{\text{mid}} \cdot \ell_{\tau=0.60} + w_{\text{high}} \cdot \ell_{\tau_{\text{user}}}] \quad (4.9)$$

donde $\ell_{\tau}(y, \hat{y}) = \max(\tau(y - \hat{y}), (\tau - 1)(y - \hat{y}))$ es la pérdida de cuantil estándar.

Las regiones se definen mediante transiciones suaves (sigmoide):

- **Zona baja** ($y < \text{-low_threshold}$ mm): $\tau = 0.50$ (mediana), captura eventos débiles
- **Zona media** ($\text{-low_threshold} \leq y \leq \text{-high_threshold}$): $\tau = 0.60$, transición intermedia
- **Zona alta** ($y > \text{-high_threshold}$ mm): $\tau = \text{-quantile_tau}$, captura eventos extremos

Los pesos w_{low} , w_{mid} , w_{high} se calculan mediante normalización softmax de las salidas sigmoides para garantizar $\sum w_i = 1$.

3. Pérdida de Tweedie La distribución Tweedie es una distribución compuesta Poisson-Gamma natural para datos de precipitación. La pérdida es:

$$\mathcal{L}_{\text{Tweedie}} = \mathbb{E} \left[-y_{\text{mm}} \cdot \hat{y}_{\text{mm}}^{-(1-p)} / (1-p) + \hat{y}_{\text{mm}}^{(2-p)} / (2-p) \right] / s_{\text{tw}} \quad (4.10)$$

donde $p = \text{-tweedie_power} \in (1, 2)$ interpola entre Poisson ($p = 1$) y Gamma ($p = 2$). El parámetro $s_{\text{tw}} = 1.0/(2-p)$ normaliza la escala cuando `-tweedie_scale_norm` es verdadero, mejorando la estabilidad numérica.

4. Pérdida de Correlación de Pearson Maximiza la correlación espacial entre predicciones y observaciones:

$$\mathcal{L}_{\text{Correlación}} = 1.0 - r_{\text{Pearson}} \quad (4.11)$$

donde:

$$r_{\text{Pearson}} = \frac{\text{Cov}(\hat{y}, y)}{\sigma_{\hat{y}} \cdot \sigma_y} \quad (4.12)$$

5. Pérdida de Suavizado Espacial Penaliza diferencias grandes entre predicciones de píxeles adyacentes, promoviendo coherencia espacial:

$$\mathcal{L}_{\text{Suavizado}} = \text{-smooth_weight} \cdot \mathbb{E} \left[\sum_{\text{pares vecinos}} (\hat{y}_i - \hat{y}_j)^2 \right] \quad (4.13)$$

Normalización EMA de componentes

Durante el entrenamiento, las magnitudes relativas de cada componente pueden variar significativamente. Para mantener equilibrio automático, el modelo utiliza medias móviles exponenciales (EMA) que se actualizan solo durante los primeros 50 pasos de entrenamiento (fase de *warmup*):

$$\text{EMA}_i^{(t)} = \begin{cases} \mathcal{L}_i & \text{si } t = 0 \\ \alpha \cdot \text{EMA}_i^{(t-1)} + (1 - \alpha) \cdot \mathcal{L}_i & \text{si } 0 < t \leq 50 \\ \text{EMA}_i^{(50)} & \text{si } t > 50 \end{cases} \quad (4.14)$$

donde $\alpha = 0.95$ es el momentum. Cada componente se normaliza dividiéndola por su EMA estática:

$$\mathcal{L}_{\text{total}} = w_H \cdot \frac{\mathcal{L}_{\text{Huber}}}{\text{EMA}_H} + w_Q \cdot \frac{\mathcal{L}_{\text{Quantil}}}{\text{EMA}_Q} + \dots \quad (4.15)$$

Esto garantiza que componentes de escalas muy diferentes contribuyan equitativamente a los gradientes.

Argumentos principales de entrenamiento

A continuación se describen los argumentos de línea de comandos más relevantes que controlan el entrenamiento del modelo:

Pérdida – Componente Huber

- `-huber_delta`: Punto de transición del criterio de Huber entre pérdida cuadrática y lineal (en unidades transformadas). Valor por defecto: 1.0.
- `-extreme_boost`: Factor multiplicativo para amplificar gradientes en eventos extremos. Valor por defecto: 3.5.

Pérdida – Componente Quantil

- `-quantile_weight`: Peso relativo de la pérdida de cuantil en la pérdida total. Valor por defecto: 0.30.
- `-quantile_tau`: Valor de cuantil τ usado en la zona de intensidad alta. Valor por defecto: 0.72.
- `-low_threshold`: Umbral inferior de precipitación en mm (frontera zona baja/media). Valor por defecto: 50.0.
- `-high_threshold`: Umbral superior de precipitación en mm (frontera zona media/alta). Valor por defecto: 250.0.

Pérdida – Componente Tweedie

- `-tweedie_weight`: Peso relativo de la pérdida de Tweedie. Valor por defecto: 0.40.
- `-tweedie_power`: Parámetro $p \in (1, 2)$ de la distribución Tweedie. Valor por defecto: 1.30.
- `-tweedie_scale_norm`: Si verdadero, normaliza la escala de Tweedie por el factor $1/(2 - p)$. Valor por defecto: `true`.

Pérdida – Componentes Adicionales

- `-corr_weight`: Peso relativo de la pérdida de correlación de Pearson. Valor por defecto: 0.10.
- `-smooth_weight`: Peso relativo de la pérdida de suavizado espacial. Valor por defecto: 0.005.

Arquitectura y Entrenamiento

- `-spatial_embed`: Dimensionalidad inicial de proyección espacial en cada torre. Valor por defecto: 256.
- `-temporal_dim`: Dimensionalidad de las capas BiLSTM. Valor por defecto: 128.
- `-hidden_dim`: Dimensionalidad de las capas Dense del decodificador. Valor por defecto: 256.
- `-n_attn_heads`: Número de cabezas en el mecanismo de multi-head attention. Valor por defecto: 8.
- `-pixel_embed_dim`: Dimensionalidad del embedding por píxel para ajuste fino. Valor por defecto: 64.
- `-coord_embed_dim`: Dimensionalidad de modulación por coordenadas geográficas. Valor por defecto: 32.

Datos y Preprocesamiento

- `-input_days`: Número de días históricos como entrada temporal. Valor por defecto: 31.
- `-batch_size`: Tamaño de batch para entrenamiento (ajustado automáticamente si excede RAM). Valor por defecto: 64.
- `-epochs`: Número máximo de épocas de entrenamiento. Valor por defecto: 500.
- `-target_transform`: Transformación del target: `log1p`, `cbrt`, `pow025`, `pow05`, `standard`, `none`. Valor por defecto: `log1p`.
- `-pca_components`: Componentes PCA: > 0 = fijo, 0 = automático (retiene varianza), -1 = sin PCA. Valor por defecto: 1500.
- `-pca_variance`: Varianza explicada objetivo para PCA automático. Valor por defecto: 0.999.

Regularización y aumento de datos (*data augmentation*)

- `-noise_std`: Desviación estándar del ruido gaussiano aditivo en augmentation. Valor por defecto: 0.05.
- `-mixup_alpha`: Parámetro α de la distribución Beta para mixup. Valor por defecto: 0.40.

- `-l2_output`: Regularización L2 en la capa de salida. Valor por defecto: 10^{-5} .
- `-grad_accum_steps`: Pasos de acumulación de gradientes (simula batch mayor). Valor por defecto: 1.

Optimización y aprendizaje

- `-use_swa`: Activar Stochastic Weight Averaging en la última fase de entrenamiento. Valor por defecto: `false`.
- `-prefetch`: Número de batches a precargar `tf.data`. Valor por defecto: 2.
- `-max_ram_gb`: Límite de RAM para el proceso (control de bajo nivel). Valor por defecto: 4.0.

Reproducibilidad

- `-seed`: Semilla para reproducibilidad global (Python, NumPy y TensorFlow). Valor por defecto: 42.
- `-seed_split`: Semilla independiente para la división train/validation. Valor por defecto: igual a `-seed`.

Interacción de parámetros y recomendaciones

- **Balance de la pérdida**: Si se ajustan w_Q , w_T o w_C , la suma $w_Q + w_T + w_C$ debe ser estrictamente menor a 1.0 para garantizar $w_H > 0$. El código genera un error si esta condición no se cumple.
- **Umbrales de quantil**: Los valores de `-low_threshold` y `-high_threshold` deben ser representativos del rango de precipitación esperado. Valores típicos están en el rango 30-150 mm (baja), 100-300 mm (alta). Las transiciones suaves (sigmoide) garantizan cambios continuos.
- **Potencia de distribución Tweedie**: El valor $p \in (1, 2)$ controla el sesgo entre Poisson ($p \approx 1$, enfatiza ceros) y Gamma ($p \approx 2$, enfatiza cola).
- **Auto-batch**: Si `-batch_size` excede la memoria disponible calculada por el monitor RAM, se reduce automáticamente y se incrementa `-grad_accum_steps` para mantener un batch efectivo similar.
- **Spatial embed $\gg$ PCA**: Si $w_Q + w_T + w_C < 0.5$, la pérdida de Huber domina. En ese caso, aumentar `-huber_delta` (más tolerancia a valores atípicos) o `-extreme_boost` (más énfasis en valores extremos).

Implementación de Control de Memoria (Low-RAM)

El modelo implementa un monitoreo dinámico de RAM en tiempo real mediante RAMMonitor:

- **Límite configurable:** El argumento `-max_ram_gb` especifica la RAM máxima que el proceso puede usar. El monitor mantiene un margen de seguridad del 20%.
- **Lectura desde disco:** Los predictores y target nunca se cargan completamente en RAM. Se utilizan memmap de NumPy en modo lectura que aprovechan el *page cache* del sistema operativo.
- **Procesamiento por chunks:** Las operaciones de estadística, PCA, y predicción se procesan en chunks temporales cuyo tamaño se ajusta dinámicamente según la RAM disponible.
- **Liberado de memoria:** Se ejecuta `gc.collect()` después de cada etapa intensiva para liberar memoria inmediatamente.

Esta arquitectura permite entrenar modelos con predictores de cientos de miles de píxeles incluso en máquinas con 4 GB de RAM, repartiendo la carga entre procesamiento en disco (I/O rápido) y cálculo (GPU/CPU).

4.7 Evaluación del modelo

4.7.1 Métricas de error global

El desempeño predictivo se cuantificó mediante:

1. RMSE (Raíz del error cuadrático medio).
2. MAE (Error Absoluto Medio).
3. Coeficiente de Determinación (R^2).
4. Correlación de Pearson (r).

4.7.2 Métricas de eficiencia de modelos hidrológicos

Se incluyeron las métricas estándar en la predicción de precipitación:

1. Nash-Sutcliffe Efficiency (NSE).
2. Kling-Gupta Efficiency (KGE).

3. Porcentaje de Sesgo (PBIAS):

$$\text{PBIAS} = 100 \cdot \frac{\sum(\hat{y}_i - y_i)}{\sum y_i} \quad (4.16)$$

Cuantifica si el modelo tiende a subestimar o sobreestimar la precipitación.

4.7.3 Análisis temporal y espacial

Para diagnosticar fortalezas y debilidades del modelo:

1. **Variación mensual:** Se calcularon RMSE, bias, correlación y KGE para cada mes del año, identificando estaciones de mejor/peor desempeño.
2. **Variación interanual:** Métricas agregadas por año hidrológico permiten detectar épocas de reducida habilidad predictiva (ej. bajo impacto de ENSO).
3. **Análisis de extremos:** Se evaluó desempeño específicamente en percentiles altos (P90, P95, P99) de precipitación, críticos para alerta temprana.
4. **Mapas espaciales:** Se generaron grillas de bias, RMSE, correlación, NSE y KGE píxel a píxel, revelando heterogeneidad geográfica del error.

4.7.4 Distribuciones y estadísticas de entrenamiento

Con el propósito de complementar, se consideró lo siguiente:

1. **QQ-plot:** Gráfico de cuantiles observados vs predichos, que expone desviaciones sistemáticas en colas.
2. **Función de distribución acumulada (CDF):** Comparación de CDFs observada y predicha, útil para verificar sesgo en percentiles.
3. **Percentiles cruzados:** Tabla de P10, P25, P50, P75, P90, P95 observados vs predichos, con razones que diagnostican compresión o dilatación de rango.

4.8 Diagnósticos ejecutados

Se desarrolló un programa de diagnósticos (`DIAGNÓSTICOS.py`) generando figuras y reportes estadísticos completos. Entre los diagnósticos clave se encuentran:

- Dispersión de predicciones vs observaciones.
- Mapas espaciales de bias medio, RMSE, y correlación por píxel.

- Series temporales agregadas (promedio espacial) con intervalos intercuartílicos.
- Ciclo anual (promedio mensual climatológico).
- Métricas mensuales y anuales en tabla y gráficos.
- Análisis de extremos (percentiles altos).
- QQ-plot y función de distribución acumulada.
- Mapas de eficiencia (NSE, KGE) por píxel.
- Evolución temporal del error (RMSE y bias por paso temporal).

Los resultados se exportan tanto a figuras PNG (si se especifica `-save`) como a un archivo NetCDF con métricas espaciales (`*_diagnosticos.nc`) para análisis posterior.

Cada una de las combinaciones de predictores descritas anteriormente fue evaluada múltiples veces mediante estas métricas, aleatorizando los meses de entrenamiento y validación, con el fin de concluir cuál era el conjunto de predictores más efectivo para el pronóstico. La elección de la alineación óptima se infirió con base en el script `COMPARACIÓN.py`.

4.9 Procedimiento de Predicción operativa

Una vez entrenado y validado un modelo, se utiliza en modo predicción mediante el script `PRONÓSTICO.py`. El procedimiento es:

1. **Cargar metadatos:** Se leen los parámetros de entrenamiento (normalización, PCA, transformación objetivo, etc.) desde `metadata.json` y los modelos PCA desde cache.
2. **Validar predictores:** Se verifica que los archivos NetCDF nuevos posean la misma grilla, dimensionalidad y cobertura temporal que los datos de entrenamiento.
3. **Procesar ventanas:** Para cada mes objetivo, se extrae una ventana de L días previos, se normaliza, se aplica PCA, y se forma el tensor de entrada.
4. **Predicción:** El modelo LSTM infiere sobre las secuencias procesadas, generando valores en el espacio transformado.
5. **Inversión y clipping:** Las predicciones se transforman inversamente a milímetros, se clipean a rangos físicos plausibles, y se reconstruye la grilla 2D.
6. **Exportación:** El resultado se guarda en formato NetCDF4 con metadatos descriptivos.

4.10 Procesamiento geográfico de resultados

Para análisis geográficos específicos (ej. desempeño en un departamento o región específica, mediante el paquete `gtMapTools` que incluye los `shapes` específicos del país utilizados en los análisis de INSIVUMEH), se implementó el script `DEP.py`, que:

1. Carga un archivo de predicciones NetCDF (típicamente `modelo_pixel_predictions.nc`).
2. Utiliza un archivo *shape* de departamentos de Guatemala para definir polígonos.
3. Construye una máscara espacial (píxel dentro/fuera del polígono) usando geometría computacional.
4. Aplica la máscara a todos los pasos de tiempo de predicciones y observaciones.
5. Exporta un NetCDF recortado conservando la dimensión temporal completa.

Este tipo de recorte geográfico es útil para validación regional y para productos operativos específicos de una zona. Por ejemplo, para propósitos de este documento, se consideró el *shape* asociado a Bocacosta y se realizaron los diagnósticos de acuerdo a las variables de esa región. Y se utilizaron las métricas locales para elegir la combinación óptima de predictores para pronóstico de precipitación en la zona.

5 Resultados

5.1 Desempeño para distintos conjuntos de predictores

Se analizó el rendimiento de la red neuronal para el pronóstico de precipitación para la región específica de Bocacosta, mediante las métricas de validación en el entrenamiento. Comparando cada uno de los conjuntos de predictores numerados en la subsección 4.2.1, con el objetivo de encontrar la mejor combinación posible para un adecuado pronóstico. Los resultados fueron los siguientes:




Fig. 5.1: Comparación de métricas para distintos predictores




Fig. 5.2: Los resultados muestran que la combinación óptima de predictores fue: SST, tp y MJO.

En donde el *score promedio* es un promedio de rankings multi-métrica, donde todas las métricas pesan igual y el objetivo es minimizar ese promedio. Así, la combinación 4 resultó ser la más eficaz, es decir, SST, tp y MJO. Se entrenó el modelo con esta combinación para hacer el análisis de pronósticos de las secciones posteriores.

5.2 Métricas de validación para el territorio nacional

Se obtuvieron los siguientes resultados para toda la región guatemalteca, para la validación de un entrenamiento considerado desde el 1 de enero de 1981 hasta el 31 de diciembre de 2024:

Estadísticas globales						
RMSE	= 80.5953					
MAE	= 56.0282					
Bias (media)	= -0.2901					
% Bias	= -0.19 %					
Std(error)	= 80.5948					
R ²	= 0.6348					
Pearson r	= 0.7979 (p=0.00e+00)					
Spearman	= 0.8431 (p=0.00e+00)					
Nash-Sutcliffe	= 0.6348					
Kling-Gupta (KGE)	= 0.7435					
Métricas por mes						
Mes	RMSE	MAE	Bias	r	NSE	KGE
Ene	55.120	36.127	-20.822	0.765	0.511	0.532
Feb	34.379	22.299	14.362	0.761	0.250	0.500
Mar	33.291	21.433	5.791	0.578	0.227	0.526
Abr	50.620	36.736	2.151	0.386	0.013	0.337
May	89.026	64.347	-23.209	0.626	0.347	0.456
Jun	97.403	76.168	7.719	0.590	0.311	0.529

```

Jul 112.017 86.955 41.622 0.653 0.333 0.442
Ago 99.861 72.419 -11.995 0.726 0.491 0.475
Sep 106.291 80.194 -40.323 0.548 0.155 0.440
Oct 92.504 72.770 20.551 0.592 0.293 0.506
Nov 74.127 54.606 -6.837 0.668 0.434 0.584
Dic 64.787 44.968 4.088 0.597 0.273 0.575

```

Análisis de extremos (percentiles)

```

P90 (>= 331.1 mm): n=28187, r=0.381, RMSE=161.9, Bias=-118.8
P95 (>= 406.6 mm): n=14094, r=0.326, RMSE=201.4, Bias=-165.4
P99 (>= 572.9 mm): n=2819, r=0.229, RMSE=317.1, Bias=-289.3

```

Percentiles cruzados

```

P10 obs= 11.75 pred= 14.42 ratio=1.227
P25 obs= 43.34 pred= 54.59 ratio=1.260
P50 obs= 121.64 pred= 135.64 ratio=1.115
P75 obs= 222.12 pred= 226.93 ratio=1.022
P90 obs= 331.13 pred= 307.85 ratio=0.930
P95 obs= 406.58 pred= 355.25 ratio=0.874

```

En donde la eficiencia del modelo en los píxeles del mapa queda representada como sigue:




Fig. 5.3: NSE y KGE para el territorio nacional en los datos de validación del entrenamiento.




Fig. 5.4: Sesgo medio, RMSE y correlación de Pearson para el territorio nacional en los datos de validación del entrenamiento.

Las métricas mensuales y el ciclo anual medio obtenidos fueron los siguientes:




Fig. 5.5: RMSE, sesgo medio, correlación de Pearson y coeficiente de Kling-Gupta mensuales medios para los datos de validación del entrenamiento.




Fig. 5.6: Precipitación media mensual para los datos de validación del entrenamiento en el territorio nacional.

5.3 Métricas de validación para la región de Bocacosta

En particular, para la región de Bocacosta se obtuvo que:

Estadísticas globales	
RMSE	= 110.4970
MAE	= 74.6254
Bias (media)	= -12.9062
% Bias	= -6.13 %
Std(error)	= 109.7406
R ²	= 0.6814
Pearson r	= 0.8281 (p=0.00e+00)
Spearman	= 0.8636 (p=0.00e+00)
Nash-Sutcliffe	= 0.6814
Kling-Gupta (KGE)	= 0.7524

Métricas por mes						
Mes	RMSE	MAE	Bias	r	NSE	KGE
Ene	22.982	15.408	-10.469	0.292	-0.156	-0.147
Feb	14.137	10.177	3.708	0.083	-0.656	-0.039
Mar	40.034	26.093	-6.367	0.145	-0.238	0.046
Abr	95.424	75.495	6.043	0.095	-0.259	0.013
May	175.586	114.414	-89.871	0.458	-0.071	0.206
Jun	110.029	89.730	-7.688	0.510	0.237	0.397
Jul	134.683	113.894	107.037	0.443	-1.510	0.233
Ago	164.154	129.000	-13.728	0.562	0.261	0.207
Sep	149.160	118.770	-59.664	0.198	-0.328	0.089
Oct	111.057	90.556	-47.196	0.530	0.114	0.381
Nov	97.630	76.933	-25.384	0.223	-0.069	0.018
Dic	31.536	25.165	-10.888	0.171	-0.200	-0.035

Análisis de extremos (percentiles)

P90 (≥ 486.9 mm): $n=1726$, $r=0.103$, $RMSE=241.4$, $Bias=-203.8$

P95 (≥ 570.8 mm): $n=863$, $r=0.036$, $RMSE=300.5$, $Bias=-270.5$

P99 (≥ 746.7 mm): $n=173$, $r=-0.147$, $RMSE=454.4$, $Bias=-437.1$

Percentiles cruzados

P10	obs=	5.03	pred=	9.03	ratio=1.793
P25	obs=	29.46	pred=	24.44	ratio=0.830
P50	obs=	169.16	pred=	199.29	ratio=1.178
P75	obs=	346.15	pred=	338.45	ratio=0.978
P90	obs=	486.88	pred=	416.63	ratio=0.856
P95	obs=	570.84	pred=	455.79	ratio=0.798

Las métricas mensuales y el ciclo anual medio obtenidos fueron los siguientes:




Fig. 5.7: RMSE, sesgo medio, correlación de Pearson y coeficiente de Kling-Gupta mensuales medios para los datos de validación del entrenamiento en la región de Bocacosta.





Fig. 5.8: Precipitación media mensual para los datos de validación del entrenamiento en la región de Bocacosta.


5.4 Comparación con el método

5.5 Comparación con la precipitación real del año 2025


Se utilizó el modelo entrenado en la sección 5.2 para pronosticar todos los meses del 2025, utilizando por tanto, los predictores de SST, TP; RMM1 y RMM2 de las MJO de treinta y un días previos al mes objetivo, y se obtuvieron los siguientes resultados:




(a) Pronóstico de precipitación acumulada para el mes de enero de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de enero de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de febrero de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de febrero de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de marzo de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de marzo de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de abril de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de abril de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de mayo de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de mayo de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de junio de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de junio de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de julio de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de julio de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de agosto de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de agosto de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de septiembre de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de septiembre de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de octubre de 2025 dado por la LSTM.




(b) Precipitación acumulada para el mes de octubre de 2025 dado por el registro de datos ENACTS.




(a) Pronóstico de precipitación acumulada para el mes de noviembre de 2025 dado por la LSTM.



(b) Precipitación acumulada para el mes de noviembre de 2025 dado por el registro de datos ENACTS.



(a) Pronóstico de precipitación acumulada para el mes de diciembre de 2025 dado por la LSTM.



(b) Precipitación acumulada para el mes de diciembre de 2025 dado por el registro de datos ENACTS.

6 Discusión de resultados

7 Conclusiones

8 Recomendaciones

Bibliografía

- [1] Damián Jorge Matich. Redes neuronales: Conceptos básicos y aplicaciones. *Universidad Tecnológica Nacional, México*, 41:12–16, 2001.
- [2] Rodrigo Salas. Redes neuronales artificiales. *Universidad de Valparaíso. Departamento de Computación*, 1(1):1–7, 2004.
- [3] Claudio Javier Tablada and Germán Ariel Torres. Redes neuronales artificiales. *Revista de educación matemática*, 24(3), 2009.
- [4] Fernando Izaurieta and Carlos Saavedra. Redes neuronales artificiales. *Departamento de Física, Universidad de Concepción Chile*, 2000.
- [5] Warren S. McCulloch and Walter Pitts. A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 5:115–133, 1943.
- [6] Masoud Hessami, Philippe Gachon, Taha B.M.J. Ouarda, and André St-Hilaire. Automated regression-based statistical downscaling tool. *Environmental Modelling Software*, 23(6):813–834, 2008.
- [7] Mohammad Taghi Sattari, Anca Avram, Halit Apaydin, and Oliviu Matei. Evaluation of feature selection methods in estimation of precipitation based on deep learning artificial neural networks. *Water Resources Management*, 37(15):5871–5891, 2023.
- [8] Pablo Rozas Larraondo, Luigi J. Renzullo, Inaki Inza, and Jose A. Lozano. A data-driven approach to precipitation parameterizations using convolutional encoder-decoder neural networks, 2019.
- [9] Dry adiabatic lapse rate. <https://www.tpub.com/weather3/7.htm>, n.d. Archived from the original on 2016-06-03.
- [10] L. D. Landau and E. M. Lifshitz. *Fluid Mechanics*, volume 6 of *Course of Theoretical Physics*. Butterworth-Heinemann, Oxford, 1987.
- [11] Todd S Glickman. *Glossary of meteorology*. American Meteorological Soc., 2000.
- [12] Richard P. Feynman. Illustrations of thermodynamics. In *The Feynman Lectures on Physics, Vol. I*. California Institute of Technology, Pasadena, CA, 1963.
- [13] Alfred Brian Pippard. *Elements of classical thermodynamics: for advanced students of physics*. Cambridge University Press, 1964.

- [14] Alexei V. Korolev and Ilia P. Mazin. Supersaturation of water vapor in clouds. *Journal of the Atmospheric Sciences*, 60(24):2957 – 2974, 2003.
- [15] Robert A Houze Jr. *Cloud dynamics*, volume 104. Academic press, 2014.
- [16] Michael Pidwirny. Cloud formation processes. In *physicalgeography. net*. 2006.
- [17] National Weather Service. Cloud development. NOAA/National Weather Service.
- [18] B Geerts. Convective and stratiform rainfall in the tropics. *University of Wyoming*, 2002.
- [19] CULACION ATMOSFERICA. El viento. *Agroclimatología tropical*, page 143, 1986.
- [20] JL Herrera. Descripción climática de los departamentos de guatemala. *Guatemala, Guatemala*, 2017.
- [21] C David Whiteman. *Mountain meteorology: fundamentals and applications*. Oxford University Press, 2000.
- [22] Mmathapelo Makgabutlane. Convergence. About MetService.
- [23] I Iglesias, MN Lorenzo, M Gómez-Gesteira, and JJ Taboada. La temperatura superficial del mar como herramienta de predicción climática. *Av. Cienc. Tierra*, 11:95–108, 2010.
- [24] William Cabos, Francisco José Álvarez García, Emilia Sánchez Gómez, and María José Ortiz Bevia. Influencia de las temperaturas superficiales del mar sobre la precipitación en el atlántico tropical. *Publicaciones de la Asociación Española de Climatología. Serie A; 3*, 2002.
- [25] J David Neelin, David S Battisti, Anthony C Hirst, Fei-Fei Jin, Yoshinobu Wakata, Toshio Yamagata, and Stephen E Zebiak. Enso theory. *Journal of Geophysical Research: Oceans*, 103(C7):14261–14290, 1998.
- [26] Raymond T Pierrehumbert, Hélène Brogniez, and Rémy Roca. On the relative humidity of the atmosphere. *The global circulation of the atmosphere*, 143:185, 2007.
- [27] JoséP Peixoto and Abraham H Oort. The climatology of relative humidity in the atmosphere. *Journal of climate*, 9(12):3443–3463, 1996.
- [28] Kevin E Trenberth, Aiguo Dai, Roy M Rasmussen, and David B Parsons. The changing character of precipitation. *Bulletin of the American Meteorological Society*, 84(9):1205–1218, 2003.

- [29] Christoph Frei, Christoph Schär, Daniel Lüthi, and Huw C Davies. Heavy precipitation processes in a warmer climate. *Geophysical Research Letters*, 25(9):1431–1434, 1998.
- [30] So-Young Yim, Bin Wang, Jian Liu, and Zhiwei Wu. A comparison of regional monsoon variability using monsoon indices. *Climate dynamics*, 43(5):1423–1437, 2014.
- [31] Harald Sodemann and Andreas Stohl. Moisture origin and meridional transport in atmospheric rivers and their association with multiple cyclones. *Monthly Weather Review*, 141(8):2850–2868, 2013.
- [32] AM Durán-Quesada and L Gimeno. Revisión de los campos medios característicos del jet de bajo nivel del caribe y algunas evaluaciones energéticas. *Av. en Cienc. la Tierra*, 1:1–38, 2010.
- [33] David J Raymond, Christopher S Bretherton, and John Molinari. Dynamics of the intertropical convergence zone of the east pacific. *Journal of the atmospheric sciences*, 63(2):582–597, 2006.
- [34] Christoph C Raible, Ute Luksch, and Klaus Fraedrich. Precipitation and northern hemisphere regimes. *Atmospheric Science Letters*, 5(1-4):43–55, 2003.
- [35] Aiguo Dai and TML Wigley. Global patterns of enso-induced precipitation. *Geophysical Research Letters*, 27(9):1283–1286, 2000.
- [36] Geert Jan Van Oldenborgh and Gerrit Burgers. Searching for decadal variations in enso precipitation teleconnections. *Geophysical Research Letters*, 32(15), 2005.
- [37] Xun Sun, Benjamin Renard, Mark Thyer, Seth Westra, and Michel Lang. A global analysis of the asymmetric effect of enso on extreme precipitation. *Journal of Hydrology*, 530:51–65, 2015.
- [38] Jialin Lin and Taotao Qian. The atlantic multi-decadal oscillation. *Atmosphere-Ocean*, 60(3-4):307–337, 2022.
- [39] Marcia Glaze Wyatt, Sergey Kravtsov, and Anastasios A Tsonis. Atlantic multi-decadal oscillation and northern hemispheres climate variability. *Climate dynamics*, 38(5):929–949, 2012.
- [40] Tito Maldonado, Eric Alfaro, Anna Rutgersson, and Jorge A Amador. The early rainy season in central america: the role of the tropical north atlantic ssts. *International Journal of Climatology*, 37(9):3731–3742, 2017.
- [41] Albenis Pérez-Alarcón, José C Fernández-Alvarez, Rogert Sorí, Raquel Nieto, and Luis Gimeno. The combined effects of sst and the north atlantic subtropical high-pressure

- system on the atlantic basin tropical cyclone interannual variability. *Atmosphere*, 12(3):329, 2021.
- [42] Kevin E Trenberth and Dennis J Shea. Relationships between precipitation and surface temperature. *Geophysical Research Letters*, 32(14), 2005.
- [43] Thomas Spengler, Joseph Egger, and Stephen T Garner. How does rain affect surface pressure in a one-dimensional framework? *Journal of the atmospheric sciences*, 68(2):347–360, 2011.
- [44] TGJ Dyer. Meridional interactions between rainfall and surface pressure. *Nature*, 264(5581):48–49, 1976.
- [45] Paris Francisco Rivera Ramos and Marvin Roberto Salguero Barahona. Influencia de la oscilación madden-julian en la lluvia de la región sur de guatemala durante el periodo de 1980–2015. *Revista de la Escuela de Estudios de Postgrado*, (1):35–42, 2022.
- [46] Andrew G Marshall, Harry H Hendon, Tom H Durrant, and Mark A Hemer. Madden julian oscillation impacts on global ocean surface waves. *Ocean Modelling*, 96:136–147, 2015.
- [47] Chidong Zhang. Madden-julian oscillation. *Reviews of Geophysics*, 43(2), 2005.
- [48] Timothy G. F. Kittel and Kelly Ferron. Nonlinear earth system dynamics determine biospheric structure and function: Ia primer on how the climate system functions as a heat engine and structures the biosphere. *Climate*, 14(2), 2026.
- [49] Luis Antonio Vázquez López. La incertidumbre de las catástrofes climáticas. *INGENIERÍA Y TERRITORIO* · 74, page 36, 2006.
- [50] Jörn Dunkel. The navier-stokes equations. Lecture notes for 18.354J Nonlinear Dynamics II: Continuum Systems, MIT OpenCourseWare, 2015. Accessed: 2026-04-27.
- [51] Stephen W Ellacott, John C Mason, and Iain J Anderson. *Mathematics of neural networks: models, algorithms and applications*, volume 8. Springer Science & Business Media, 2012.
- [52] Larry R Medsker, Lakhmi Jain, et al. Recurrent neural networks. *Design and applications*, 5(64-67):2, 2001.
- [53] John F. Kolen and Stefan C. Kremer. *Gradient Flow in Recurrent Nets: The Difficulty of Learning LongTerm Dependencies*, pages 237–243. 2001.

- [54] Soonchan Park and Heechan Han. Application of lstm and climate index for prediction of meteorological drought in south korea. *Water*, 17(12), 2025.
- [55] Noguer I Alonso et al. The mathematics of recurrent neural networks. *The Mathematics of Recurrent Neural Networks (October 27, 2024)*, 2024.
- [56] Rob J. Hyndman and Anne B. Koehler. Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4):679–688, 2006.
- [57] Juan Diego Hernández Lalinde, Franklin Espinosa Castro, Johel E Rodríguez, José Gerardo Chacón Rangel, Cristian Andrés Toloza Sierra, Marlly Karina Arenas Torrado, Sandra Milena Carrillo Sierra, and Valmore José Bermúdez Pirela. Sobre el uso adecuado del coeficiente de correlación de pearson: definición, propiedades y suposiciones. *Archivos venezolanos de Farmacología y Terapéutica*, 37(5):587–595, 2018.
- [58] Axel Ritter and Rafael Muñoz-Carpena. Performance evaluation of hydrological models: Statistical significance for reducing subjectivity in goodness-of-fit assessments. *Journal of Hydrology*, 480:33–45, 2013.
- [59] Hoshin Vijai Gupta and Harald Kling. On typical range, sensitivity, and normalization of mean squared error and nash-sutcliffe efficiency type metrics. *Water Resources Research*, 47(10), 2011.
- [60] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56):1929–1958, 2014.
- [61] Federico Girosi, Michael Jones, and Tomaso Poggio. Regularization theory and neural networks architectures. *Neural Computation*, 7(2):219–269, 03 1995.
- [62] Martínez Acosta et al. Contribución económica del componente forestal en diferentes tipos de fincas cafetaleras en la bocacosta pacífica de guatemala. 2005.
- [63] Cesar Eduardo Ordóñez Morales, Enrique Loras Castillo, Marco Alirio Ochoa Galicia, Herbert Loarca Moreira, and Irina Reyes. Acceso a la tierra y organización productiva en la boca costa quetzalteca, guatemala. *Cuadernos Geográficos*, 41:149–172, 2007.
- [64] Mohaiminul Islam, Guorong Chen, and Shangzhu Jin. An overview of neural network. *American Journal of Neural Networks and Applications*, 5(1):7–11, 2019.
- [65] Sepp Hochreiter. Recurrent neural net learning and vanishing gradient. *International Journal Of Uncertainty, Fuzziness and Knowledge-Based Systems*, 6(2):107–116, 1998.

- [66] Juan Antonio Pérez Ortiz. Modelos predictivos basados en redes neuronales recurrentes de tiempo discreto. *Universidad de Alicante. Departamento de lenguaje y sistemas informáticos.*[Documento en línea http://www.conicyt.cl/573/Modelos_predictivos_basados_en_redes_neuronales_recurrentes_de_tiempo_discreto.pdf][22/07/08], 2002.
- [67] Stephen Grossberg. Recurrent neural networks. *Scholarpedia*, 8(2):1888, 2013.
- [68] Yong Yu, Xiaosheng Si, Changhua Hu, and Jianxun Zhang. A review of recurrent neural networks: Lstm cells and network architectures. *Neural computation*, 31(7):1235–1270, 2019.
- [69] Xuanyi Song, Yuetian Liu, Liang Xue, Jun Wang, Jingzhe Zhang, Junqiang Wang, Long Jiang, and Ziyang Cheng. Time-series well performance prediction based on long short-term memory (lstm) neural network model. *Journal of Petroleum Science and Engineering*, 186:106682, 2020.
- [70] Zahra Karevan and Johan AK Suykens. Transductive lstm for time-series prediction: An application to weather forecasting. *Neural Networks*, 125:1–9, 2020.
- [71] Russ Rew and Glenn Davis. Netcdf: an interface for scientific data access. *IEEE computer graphics and applications*, 10(4):76–82, 1990.
- [72] Lars Peter Riishojgaard, John W Zillman, Adrian Simmons, and John Eyre. Intercambio de datos en la organización meteorológica mundial: contexto, historia e impacto. 2021.
- [73] The HDF Group. Hdf5, 2024. Accessed: 2024-12-19.
- [74] National Weather Service. Divergence and convergence. https://www.weather.gov/source/zhu/ZHU_Training_Page/Miscellaneous/Divergence/divergence.html, n.d. NOAA/National Weather Service. Accessed: 2026-04-27.
- [75] Kevin E Trenberth, Johan R Christy, and Jerry G Olson. Global atmospheric mass, surface pressure, and water vapor variations. *Journal of Geophysical Research: Atmospheres*, 92(D12):14815–14826, 1987.
- [76] Richard H. McCuen, Zachary Knight, and A. Gillian Cutter. Evaluation of the nash-sutcliffe efficiency index. *Journal of Hydrologic Engineering*, 11(6):597–602, 2006.
- [77] Enrique Pazos Avalos. Análisis de la precipitación sobre el territorio guatemalteco utilizando un modelo climático regional. *Biblioteca de la Universidad de San Carlos de Guatemala*, 2018.