Universidad de San Carlos de Guatemala
Escuela de Ciencias Físicas y Matemáticas

Desarrollo de un modelo predictivo de precipitación para la región Bocacosta de Guatemala mediante redes neuronales LSTM

Informe final de ejercicio profesional supervisado elaborado por:
Miguel Alexander Avila Chacón
presentado ante el Departamento de Física

Supervisado por
Ing. Klaus Hermann Aldo Johannes Zúñiga Kaufmann
Dr. Giovanni Ramírez

Guatemala, junio de 2026

Resumen

Palabras clave: parton distribution functions & phenomenology & high energy physics.

Capítulo 1

Introducción

El ser humano se caracteriza por la búsqueda constante de herramientas que mejoren sus condiciones de vida. En los últimos años, estos esfuerzos se han orientado hacia la construcción de máquinas con algoritmos capaces de resolver, de forma automática y rápida, operaciones que resultan tediosas para una persona. Sin embargo, estas máquinas, basadas en algoritmos específicos, presentan una limitación importante: en ocasiones el problema que se busca resolver no requiere un tratamiento algorítmico sino el aprendizaje de patrones a través de la experiencia.

El ser humano es capaz de resolver múltiples problemas que no pueden expresarse mediante un algoritmo gracias a su experiencia y a su capacidad para memorizar y asociar hechos. Así, parece lógico que una forma de aproximarse a este tipo de problemas consista en construir sistemas capaces de reproducir dicha característica humana. En este sentido, las redes neuronales constituyen un intento simplificado de simular el funcionamiento del cerebro humano en el tratamiento de la información, cuya unidad básica de procesamiento se inspira en la célula fundamental del sistema nervioso: la neurona.

Una característica esencial del cerebro humano es su capacidad de aprendizaje, entendida como la habilidad de resolver problemas que inicialmente no podían abordarse, mediante la adquisición de nueva información sobre ellos [1, 2, 3, 4].

Por lo tanto, las redes neuronales se componen de unidades de procesamiento que intercambian datos o información. Se utilizan para reconocer patrones en conjuntos de datos, como imágenes, manuscritos o secuencias temporales, con el objetivo de aprender de ellos y mejorar su desempeño [1].

Debido a sus fundamentos, las redes neuronales artificiales presentan un gran número de características semejantes a las del cerebro, y por ello una gran cantidad de ventajas por sobre los programas basados en algoritmos [5]. Por ejemplo, son capaces de aprender a través de la experiencia, de generalizar de una gran serie de casos específicos a nuevos casos, de abstraer características esenciales de bancos de información, desechando la información irrelevante, etc.

Capítulo 2

Objetivos

2.1 General

Desarrollar un modelo predictivo de precipitación para la región de Bocacosta en Guatemala utilizando redes neuronales LSTM. Con datos históricos con el propósito de complementar los métodos tradicionales de pronóstico climático.

2.2 Específicos

1. Analizar series de tiempo de variables climáticas, como precipitación y temperatura, utilizando estadística descriptiva.
2. Diseñar e implementar un modelo LSTM utilizando datos históricos del INSIVUMEH.
3. Evaluar el desempeño del modelo mediante métricas de validación, como el análisis de correlación.
4. Comparar los resultados obtenidos con métodos tradicionales.

Capítulo 3

Marco teórico

3.1 Dinámica de la atmósfera

3.1.1 Conceptos básicos del sistema climático

El sistema climático terrestre es un sistema acoplado no lineal compuesto por la atmósfera, la hidrosfera, la criosfera, la litosfera y la biosfera. Su dinámica está gobernada por las leyes de conservación de la masa, el momento y la energía, así como por la ecuación de estado de los gases ideales. La fuente primaria de energía es la radiación solar de onda corta, la cual es distribuida de manera desigual sobre la superficie terrestre debido a la redondez del planeta y la inclinación del eje de rotación. Este desequilibrio radiativo genera gradientes de temperatura que impulsan la circulación general de la atmósfera y los océanos, cuyo objetivo termodinámico es transportar calor desde las regiones ecuatoriales hacia los polos.

3.1.2 Variables atmosféricas relevantes

Para caracterizar el estado de la atmósfera y su evolución, se utilizan variables de estado fundamentales. *La presión atmosférica* (P), definida como la fuerza por unidad de área ejercida por el peso de la columna de aire, decrece exponencialmente con la altura siguiendo la ecuación hipsométrica. *La temperatura* (T) es una medida de la energía cinética media de las moléculas del aire. *El contenido de vapor de agua*, que se cuantifica mediante la humedad específica (q), que representa la masa de vapor de agua por unidad de masa de aire húmedo, o la humedad relativa (HR) o (z), que indica el grado de saturación del aire respecto a la presión de vapor de saturación. *La velocidad del viento*, un campo vectorial $\vec{V} = (u, v, w)$, describe el movimiento del aire en las direcciones zonal, meridional y vertical, respectivamente [6, 7, 8].

3.1.3 Procesos termodinámicos

Los procesos adiabáticos son centrales en la formación de nubes y precipitación. Cuando una parcela de aire asciende en la atmósfera, encuentra una presión ambiental menor y se expande. Si el ascenso es lo suficientemente rápido para que el intercambio de calor con el entorno sea despreciable (proceso adiabático), la parcela se enfría a la tasa adiabática seca ($\Gamma_d \approx 9.8$ K km^{-1}). Una vez que la parcela alcanza la saturación, la condensación libera calor latente, reduciendo la tasa de enfriamiento a una tasa pseudo-adiabática húmeda (Γ_s), cuyo valor varía con la temperatura y la presión, siendo típicamente de $4-6$ K km^{-1} en la troposfera tropical. Este calor latente es una fuente crucial de energía para la convección profunda [9, 10, 11].

3.2 Mecanismos de formación de la precipitación

3.2.1 Saturación, condensación y formación de nubes

La precipitación es el resultado final de una cadena de procesos microfísicos que comienzan con la saturación del aire. La ecuación de Clausius-Clapeyron establece la relación termodinámica fundamental entre la presión de vapor de saturación (P) y la temperatura:

$$\frac{dP}{dT} = \frac{L_v P}{R_v T^2} \tag{3.1}$$

donde L_v es el calor latente de vaporización y R_v es la constante específica del vapor de agua. Esta ecuación implica que la capacidad del aire para contener vapor de agua aumenta exponencialmente con la temperatura. En un clima más cálido, la atmósfera puede retener más humedad, lo que intensifica los eventos extremos de precipitación si los mecanismos de ascenso están presentes. La condensación del vapor sobre núcleos de condensación de nubes (CCN) da lugar a las gotitas de nube, cuyo tamaño es insuficiente para precipitar por gravedad [12, 13].

3.2.2 Procesos de colisión-coalescencia y Bergeron-Findeisen

La formación de gotas de lluvia requiere el crecimiento de las partículas de condensación de nube hasta alcanzar un tamaño crítico. En nubes cálidas (temperatura $> 0°$C), predomina el proceso de **colisión-coalescencia**, donde gotas de diferente tamaño y velocidad terminal colisionan y se fusionan. En nubes frías o mixtas, opera el **proceso de Bergeron-Findeisen**, relacionada con la diferencia de presión de vapor de saturación sobre el agua líquida y el hielo. En un ambiente mixto saturado respecto al agua, existe sobresaturación respecto al hielo, lo que induce la deposición de vapor sobre los cristales de hielo a expensas de las partículas subfundidas [14].

3.2.3 Ascenso de masas de aire

Para que se produzca precipitación significativa, es indispensable el ascenso de masas de aire húmedo que enfríen la parcela hasta la saturación. Los mecanismos de ascenso principales son:

- **Convección libre:** Calentamiento diferencial de la superficie que genera burbujas de aire cálido menos denso que ascienden.
- **Ascenso orográfico:** El viento horizontal se aproxima a una barrera montañosa y es forzado a elevarse, enfriándose adiabáticamente. Este mecanismo es crítico en la Bocacosta guatemalteca.
- **Convergencia en niveles bajos:** La fricción superficial o la dinámica de ondas del este generan zonas de acumulación de masa que fuerzan el movimiento vertical ascendente.
- **Frentes:** Superficies de discontinuidad entre masas de aire de distinta densidad generan mecanismos de ascenso.

3.3 Variables físicas relevantes para la predicción de precipitación local

La selección de predictores (características de entrada) para un modelo de precipitación debe basarse en su conexión causal con los procesos de condensación y ascenso.

3.3.1 Temperatura superficial del mar (SST)

La SST es la variable oceánica más influyente en el clima tropical. Anomalías cálidas en la SST incrementan el flujo de calor latente y sensible hacia la atmósfera, reduciendo la estabilidad estática e incrementando la humedad en la capa límite. En el contexto del Pacífico Oriental, la SST modula la intensidad de la Zona de Convergencia Intertropical (ZCIT) y la convección asociada a ondas del este.

3.3.2 Humedad relativa y específica

La humedad específica (q) en niveles medios (500 hPa) es un indicador directo de la materia prima disponible para la convección. La humedad relativa (HR) proporciona información sobre qué tan cerca de la saturación se encuentra una columna atmosférica, siendo crucial para activar la convección.

3.3.3 Viento (componentes zonal y meridional)

El viento zonal (u) en niveles bajos (850 hPa) es fundamental para el transporte de humedad desde las fuentes oceánicas (el Jet de Bajo Nivel del Caribe o el flujo del Pacífico). La componente meridional (v) está asociada a la convergencia/divergencia y a la posición de la ZCIT. La cizalladura vertical del viento puede tanto inhibir como organizar los sistemas convectivos.

3.3.4 Geopotencial

La altura geopotencial (Z) en niveles de 500 hPa permite identificar la presencia de vaguadas y dorsales en la tropósfera media. Una vaguada profunda sobre Centroamérica se asocia con ascenso de gran escala y enfriamiento en la tropósfera superior, lo que desestabiliza la columna atmosférica y favorece tormentas.

3.3.5 Teleconexiones climáticas (ENSO, AMO, TNA)

El sistema climático presenta modos de variabilidad de baja frecuencia que modulan las condiciones medias de precipitación en Guatemala.

- **ENSO (El Niño-Southern Oscillation):** La fase cálida (El Niño) se asocia típicamente con déficit de precipitación en la vertiente del Pacífico guatemalteco debido al debilitamiento de los vientos alisios y al desplazamiento de la convección profunda hacia el Pacífico Central. La fase fría (La Niña) se correlaciona con excesos de lluvia.
- **AMO (Atlantic Multidecadal Oscillation):** Afecta la SST del Atlántico Norte y modula la fuerza del transporte de humedad desde el Caribe hacia el Pacífico a través del istmo.
- **TNA (Tropical North Atlantic Index):** Anomalías cálidas en el Atlántico tropical intensifican la corriente de humedad hacia Centroamérica, compitiendo con la influencia del Pacífico.

Todos estos indicadores se encuentran codificados en la evolución de la temperatura superficial del mar (SST).

3.3.6 Presión atmosférica en la superficie

Refleja directamente la dinámica de los sistemas meteorológicos en niveles bajos, donde se inician muchos de los procesos que conducen al ascenso de aire. Las zonas de baja presion suelen estar asociadas con convergencia, ascenso y desarrollo de nubosidad, mientras que los gradientes de presión determinan la intensidad y dirección del viento, influyendo en la organización del flujo atmosférico. Además, las variaciones temporales de la presión permiten identificar el desarrollo o debilitamiento de estos sistemas, aportando información sobre la evolución de los eventos de lluvia.

3.3.7 Oscilación Madden-Julian (MJO)

Relevante en la precipitación global, porque representa una variabilidad organizada de la convección tropical que se propaga a lo largo del planeta, modulando la distribución espacial y temporal de las lluvias. A través de las fases de la onda, se activan regiones de convección activa y suprimida, afectando la circulación atmosférica, los patrones de viento y la disponibilidad de humedad.

3.3.8 Precipitación global

La precipitación entendida como el campo espacial a una escala planetaria, aporta información clave porque encapsula la organización espacial de los sistemas convectivos y sinópticos, así como la interacción entre diferentes escalas de movimiento atmosférico. Esta variable codifica patrones de bandas de convección, zonas de convergencia o sistemas que evolucionan y se desplazan en el tiempo y espacio.

3.4 Series de tiempo en climatología

3.4.1 Definición y componentes

Una serie de tiempo climática es una secuencia de observaciones de una variable atmosférica ordenada cronológicamente y generalmente equiespaciada. Matemáticamente, se define como $\{X_t : t \in T\}$, donde T es el índice temporal. Estas series suelen descomponerse en tres componentes aditivos o multiplicativos:

$$X_t = T_t + S_t + R_t \tag{3.2}$$

donde T_t es la tendencia a largo plazo (cambio climático o variabilidad decadal), S_t es la estacionalidad periódica (ciclo anual marcado por el monzón centroamericano), y R_t es el residuo o variabilidad de alta frecuencia (sinóptica e intradiurna).

3.4.2 Autocorrelación

La función de autocorrelación (ACF) mide la dependencia lineal entre los valores de la serie en el tiempo t y en rezagos $t - k$. En climatología, la precipitación exhibe una persistencia significativa; la lluvia de hoy está correlacionada con la lluvia de ayer, y más aún, con la humedad del suelo o los modos de variabilidad oceánica de semanas previas. Esta propiedad justifica el uso de modelos con memoria temporal como las redes recurrentes.

3.5 Relación entre procesos físicos y aprendizaje automático

3.5.1 Naturaleza no lineal del sistema climático

La atmósfera es un fluido geofísico turbulento gobernado por las ecuaciones no lineales de Navier-Stokes. Los procesos de retroalimentación, como el acoplamiento entre la radiación de onda larga y la nubosidad, o la liberación de calor latente en función de la convergencia de humedad, generan una respuesta altamente no lineal del sistema. Esta no linealidad implica que pequeños errores en las condiciones iniciales crecen exponencialmente (caos determinista), limitando la predictibilidad de los modelos dinámicos más allá de unos pocos días para el detalle convectivo.

3.5.2 Limitaciones de modelos físicos tradicionales

Los Modelos de Circulación General (GCM) y los Modelos de Predicción Numérica del Tiempo (NWP) resuelven las ecuaciones primitivas en una malla discreta. Sin embargo, enfrentan dificultades inherentes en regiones de terreno complejo como la Bocacosta, donde la resolución espacial es insuficiente para resolver la orografía escarpada y los procesos de convección sub-malla deben ser parametrizados (aproximados empíricamente). Estas parametrizaciones introducen sesgos sistemáticos y errores en el pronóstico de precipitación orográfica.

3.5.3 Justificación del Uso de Machine Learning

El Aprendizaje Automático (ML), y en particular las redes neuronales profundas, ofrecen un enfoque complementario puramente basado en datos. Una red neuronal puede aprender empíricamente la función de mapeo $f : \mathbb{R}^n \to \mathbb{R}$ que relaciona un conjunto de predictores físicos de gran escala (resueltos por reanálisis) con la precipitación local observada. Este enfoque permite capturar relaciones estadísticas no lineales y dependencias temporales complejas que son difíciles de formular explícitamente en un modelo físico.

3.5.4 Interpretabilidad física de los predictores

Si bien las redes neuronales son a menudo criticadas como *cajas negras*, la selección cuidadosa de predictores basada en la dinámica atmosférica permte **interpretabilidad física**, asegurando que la red está utilizando información sobre la SST del Pacífico, la humedad transportada por el viento zonal y la estabilidad atmosférica para inferir la probabilidad e intensidad de la precipitación, en concordancia con la teoría de la convección.

3.6 Redes neuronales artificiales

3.6.1 Definición y modelo matemático

Una red neuronal artificial es un modelo computacional inspirado en el sistema nervioso biológico, compuesto por unidades de procesamiento interconectadas llamadas neuronas. Formalmente, una neurona artificial recibe un vector de entrada $\mathbf{x} = (x_1, x_2, ..., x_n)$, calcula una suma ponderada de estas entradas y aplica una función de activación no lineal $g(\cdot)$:

$$y = g\left(\sum_{i=1}^{n} w_i x_i + b\right) = g(\mathbf{w}^T\mathbf{x} + b) \tag{3.3}$$

donde $\mathbf{w}$ son los pesos sinápticos (parámetros ajustables que determinan la importancia de cada entrada) y b es el sesgo o *bias*.

3.6.2 Funciones de activación

La no linealidad $g(\cdot)$ es esencial para que la red pueda aproximar funciones complejas. Las funciones más comunes en modelos LSTM son:

- **Sigmoide (σ):** $\sigma(x) = \frac{1}{1+e^{-x}}$. Comprime los valores al rango $(0, 1)$, utilizada en puertas de control de flujo de información.
- **Tangente hiperbólica (**tanh**):** $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$. Comprime valores al rango $(-1, 1)$, centrada en cero, utilizada para regular el estado de la celda.
- **ReLU (Rectified Linear Unit):** $ReLU(x) = \max(0, x)$. Popular en capas ocultas densas por su eficiencia computacional y mitigación del desvanecimiento del gradiente.

3.7 Redes Neuronales Recurrentes (RNN)

3.7.1 Concepto de Memoria Temporal

Las redes neuronales *feedforward* estándar asumen independencia entre muestras, lo cual es inadecuado para series de tiempo donde X_t depende de X_{t-1}. Las Redes Neuronales Recurrentes (RNN) introducen conexiones de retroalimentación que forman un ciclo dirigido, permitiendo que la información persista. El estado oculto $\mathbf{h}_t$ actúa como una *memoria* que resume la historia pasada de la secuencia:

$$\mathbf{h}_t = g(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h) \tag{3.4}$$

donde $\mathbf{W}_{hh}$ es la matriz de pesos recurrente que propaga el estado anterior.

3.7.2 Problema del Gradiente Evanescente

El entrenamiento de RNNs mediante retropropagación a través del tiempo (BPTT) implica el cálculo de gradientes a través de múltiples pasos temporales. Debido a multiplicaciones repetidas de la matriz $\mathbf{W}_{hh}$ y las derivadas de las funciones de activación, los gradientes tienden a **desvanecerse** (tender a cero) o **explotar** (tender a infinito) a medida que los pasos de tiempo aumentan. En el contexto climático, donde la precipitación actual puede estar influenciada por la SST de varios meses atrás (teleconexiones ENSO), la RNN simple es incapaz de capturar estas dependencias de **largo plazo** debido al gradiente evanescente [15].

3.8 Redes LSTM (Long Short-Term Memory)

3.8.1 Justificación de su uso

La arquitectura LSTM fue diseñada específicamente para superar el problema del gradiente evanescente y aprender dependencias temporales de largo alcance. Dado que los fenómenos atmosféricos operan en múltiples escalas temporales (desde pequeños cambios locales en la altura geopotencial a una presión específica hasta la oscilación interanual del ENSO), la LSTM es la elección óptima para modelar la precipitación acumulada. Su capacidad para recordar y olvidar información selectivamente permite a la red mantener un estado que refleje la condición climática de fondo (fase de La Niña, Niño o Neutro) mientras reacciona a perturbaciones sinópticas de corta duración.

3.8.2 Arquitectura interna y ecuaciones fundamentales

La celda LSTM reemplaza la neurona recurrente simple por un módulo que contiene una **celda de estado** (C_t) y tres compuertas que regulan el flujo de información [16].

1. **Puerta de olvido (f_t):** Decide qué información eliminar del estado de la celda previo C_{t-1}. Observa $\mathbf{h}_{t-1}$ y $\mathbf{x}_t$, y emite un valor entre 0 (olvidar) y 1 (retener).

$$f_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \tag{3.5}$$

2. **Puerta de entrada (i_t) y candidato de celda ($\tilde{C}_t$):** Decide qué nueva información almacenar en la celda. La puerta de entrada selecciona los valores a actualizar, mientras que una capa tanh genera un vector de nuevos valores candidatos.

$$i_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \tag{3.6}$$

$$\tilde{C}_t = \tanh(\mathbf{W}_C \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \tag{3.7}$$

3. **Actualización del estado de celda (C_t):** El estado anterior se actualiza combinando la acción del olvido y la adición de la nueva información.

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \tag{3.8}$$

El flujo lineal de gradiente a través de la operación + y $*$ (producto elemento a elemento) evita el desvanecimiento del gradiente a lo largo de decenas de pasos temporales.

4. **Puerta de salida (o_t) y estado oculto (h_t):** La salida se basa en el estado de la celda, pero filtrado por una compuerta de salida que decide qué partes del estado actual son relevantes para el siguiente paso o la predicción final.

$$o_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \tag{3.9}$$

$$\mathbf{h}_t = o_t * \tanh(C_t) \tag{3.10}$$

3.9 Preprocesamiento de datos climáticos

3.9.1 Normalización y Estandarización

Las variables climáticas poseen escalas y unidades físicas dispares (por ejemplo geopotencial en m^2s^{-2}, humedad relativa en %). Para que el optimizador por gradiente converja eficientemente y las funciones de activación operen en su rango sensible, es necesario escalar los datos. La estandarización se utiliza comúnmente en climatología para preservar las anomalías relativas:

$$X_{std} = \frac{X - \mu}{\sigma} \tag{3.11}$$

donde μ es la media y σ la desviación estándar del período de entrenamiento.

3.9.2 Manejo de Datos Faltantes

Los conjuntos de datos observacionales (pluviómetros) o satelitales contienen lagunas. Se aplican técnicas de imputación como la interpolación lineal temporal o la sustitución por la mediana climatológica del mes correspondiente. Para mantener la consistencia física, es preferible eliminar segmentos cortos de reanálisis en lugar de interpolar valores espurios de viento.

3.9.3 Construcción de ventanas temporales

Para alimentar la red LSTM, la serie de tiempo continua debe ser segmentada en secuencias de longitud fija L (ventanas de entrada bien definidas). Si se predice la precipitación en el tiempo t, la entrada es la matriz $\mathbf{X} \in \mathbb{R}^{L \times N}$ donde N es el número de predictores. La

elección de L es crítica: debe ser lo suficientemente larga para capturar la evolución de una onda del este (3-5 días) y la memoria de la humedad del suelo, pero no tan larga como para diluir el gradiente en el entrenamiento.

3.9.4 División de datos

Para evaluar la capacidad de generalización del modelo, el conjunto de datos se divide en:

- **Entrenamiento:** Aproximadamente 70-80% de los datos (años iniciales o completamente aleatorios, por ejemplo). Usado para ajustar los pesos $\mathbf{W}$ y $\mathbf{b}$ mediante retropropagación.
- **Validación:** 30-20% de los datos. Usado para monitorear el rendimiento fuera de muestra y detener el entrenamiento (*early stopping*) antes del sobreajuste.
- **Prueba:** Un conjunto de datos auxiliar que proporcione una estimación insesgada del rendimiento operativo del modelo final.

3.10 Evaluación de modelos predictivos

La bondad del ajuste y la precisión del pronóstico se cuantifican mediante métricas de error y correlación.

3.10.1 RMSE (Raíz del error cuadrático medio)

Mide la desviación estándar de los residuos (errores de predicción). Penaliza fuertemente los errores grandes debido al término cuadrático (llegando a valores altos cuando se presentan eventos extremos). Es útil para cuantificar la magnitud media del error en las mismas unidades que la variable observada (mm/día).

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{3.12}$$

3.10.2 MAE (Error Absoluto Medio)

Mide la magnitud promedio de los errores en un conjunto de predicciones, sin considerar la dirección. Es menos sensible a valores atípicos extremos que el RMSE.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{3.13}$$

3.10.3 Correlación de Pearson (r)

Evalúa la relación lineal entre los valores predichos ($\hat{y}$) y los observados (y). Un valor cercano a 1 indica que el modelo captura correctamente la fase y la tendencia de la variabilidad de la precipitación, aunque pudiera tener un sesgo sistemático en la magnitud.

$$r = \frac{\sum(y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum(y_i - \bar{y})^2 \sum(\hat{y}_i - \bar{\hat{y}})^2}} \tag{3.14}$$

3.10.4 Índice de eficiencia de Nash-Sutcliffe (NSE)

Índice ampliamente utilizado para evaluar la bondad de ajuste de un modelo hidrológico. Un valor cercano a 1 indica una coincidencia perfecta entre el modelo y los datos observados. Un valor entre 0 y 1 indica valores aceptables, donde una mejor presición se asocia a valores cercanos a 1. Un valor de NSE igual que cero indica que la capacidad predictiva del modelo es igual a la de la media de los datos observados. Y un valor negativo indica que la media es un mejor predictor que el modelo propuesto.

Se calcula como la relación entre la varianza del error del modelo y la varianza de los datos observados.

$$NSE = 1 - \frac{\sum_{t=1}^{T}(Q_0^t - Q_m^t)^2}{\sum_{t=1}^{T}(Q_0^t - \bar{Q}_0)^2}. \tag{3.15}$$

Donde Q_0 es el valor observado, Q_m el valor simulado y $\bar{Q}_0$ la media de los valores observados.

Es matemáticamente idéntico al cálculo del coeficiente de correlación, sin embargo, se diferencia de este por su interpretabilidad y rango, pues NSE puede ser cualquier número negativo.

Mientras que el coeficiente de correlación mide la linealidad y co-variación, el NSE mide la precisión del modelo.

3.10.5 Eficiencia de Kling-Gupta (KGE)

Es un indicador de la bondad de ajuste de un modelo, utilizado comúnmente en las ciencias hidrológicas. Creado con el objetivo de mejorar las métricas ampliamente utilizadas, como el coeficiente de determinación y el coeficiente de eficiencia de Nash-Sutcliffe.

$$KGE = 1 - \sqrt{(r-1)^2 + (\alpha - 1)^2 + (\beta - 1)^2}. \tag{3.16}$$

Donde r es el coeficiente de correlación de Pearson, α representa la variabilidad de los errores de predicción, esto es, $\alpha = \sigma_s/\sigma_o$, donde σ_s^2 es la varianza de la serie temporal simulada y σ_o^2 es la varianza de la serie temporal observada. Finalmente β es el sesgo del modelo, entendido como $\beta = \mu_s/\mu_o$, siendo μ_s la media de los datos simulados y μ_o la media de los datos observados.

3.11 Problemas en el entrenamiento de modelos

3.11.1 Overfitting (sobreajuste)

Ocurre cuando el modelo aprende no solo la señal física subyacente, sino también el *ruido* estadístico y las idiosincrasias del conjunto de entrenamiento. Un modelo sobreajustado exhibe un error muy bajo en entrenamiento pero un error alto en validación/prueba. En el contexto de LSTM, el sobreajuste se manifiesta cuando la red memoriza secuencias específicas de años pasados en lugar de aprender las relaciones atmósfera-lluvia generalizables.

3.11.2 Underfitting (subajuste)

Sucede cuando el modelo es demasiado simple (pocas neuronas o capas) para capturar la complejidad no lineal del sistema climático. El error es alto tanto en entrenamiento como en validación, indicando que el modelo no ha logrado aprender la función de mapeo verdadera.

3.11.3 Técnicas de regularización

Para combatir el sobreajuste en redes LSTM profundas se emplean:

- **Dropout:** Durante el entrenamiento, se desactiva aleatoriamente un porcentaje p de las neuronas en cada paso (ignorando su salida y gradiente). Esto fuerza a la red a no depender de una ruta de activación específica, mejorando la robustez y actuando como un ensamble de sub-redes [17].
- **Early Stopping:** El entrenamiento se detiene cuando el error de validación deja de disminuir y comienza a aumentar, incluso si el error de entrenamiento sigue bajando. Es una de las técnicas más efectivas en series temporales climáticas [18].

3.12 Contexto climático de Guatemala y región de Bocacosta

3.12.1 Estacionalidad de la precipitación

La región Bocacosta se ubica en la vertiente sur de la cadena volcánica de Guatemala, descendiendo hacia la llanura costera del Pacífico. El régimen de precipitación es marcado y estacional, definido por el monzón de América del norte y la migración latitudinal de la Zona de Convergencia Intertropical. La temporada lluviosa se extiende típicamente de mayo a octubre, presentando un doble máximo característico: un primer pico en junio asociado al inicio de la época lluviosa y al paso de ondas del este, una canícula en julio-agosto debido a la intensificación de los vientos alisios y subsidencia, y un segundo máximo

en septiembre-octubre coincidiendo con el pico de actividad de la Zona de Convergencia Intertropical en el Pacífico Oriental y la temporada de ciclones tropicales.

3.12.2 Influencia del pacífico y rol de la orografía

La Bocacosta está directamente expuesta al flujo de humedad del Océano Pacífico tropical nororiental. La interacción entre el flujo de bajo nivel del suroeste y la pronunciada orografía de la Sierra Madre guatemalteca es el principal mecanismo forzante de la precipitación en la zona. El ascenso forzado (efecto Föehn) condensa la abundante humedad oceánica, generando núcleos de precipitación convectiva

3.12.3 Importancia de la predicción en la región

La Bocacosta es una de las zonas con más producción agrícola del país (café, caña de azúcar, hule), pero también una de las más vulnerables a eventos hidrometeorológicos extremos. La predicción precisa de la precipitación a corto y mediano plazo es un insumo fundamental para:

- Sistemas de Alerta Temprana (SAT) ante deslizamientos y crecidas de ríos.
- Planificación de siembra y cosecha en el sector agrícola.
- Gestión de recursos hídricos para generación hidroeléctrica en la vertiente del Pacífico.

El desarrollo de un modelo LSTM para la precipitación local busca complementar las limitaciones de los modelos numéricos globales, proporcionando una herramienta basada en predictores físicos de gran escala.

Capítulo 4

Metodología

4.1 Diseño general del estudio

El modelo predictivo se construyó siguiendo un enfoque de aprendizaje automático basado en una arquitectura LSTM multi-torre, la cual procesa series temporales de predictores climáticos de múltiples variables y resoluciones espaciales para estimar la precipitación mensual acumulada (en mm) en una región de interés. El flujo de trabajo se estructura en cuatro etapas principales: (1) adquisición y preprocesamiento de datos, (2) normalización y reducción de dimensionalidad, (3) entrenamiento y validación del modelo, y (4) evaluación mediante diagnósticos completos.

4.2 Adquisición y preprocesamiento de datos

4.2.1 Fuentes de datos

Los datos de precipitación observada fueron obtenidos del Instituto Nacional de Sismología, Vulcanología, Meteorología e Hidrología (INSIVUMEH) de Guatemala, consistiendo en series de tiempo diarias de precipitación medida en estaciones pluviométricas calibradas distribuidas a lo largo del país. Los predictores climáticos fueron adquiridos de fuentes globales de reanálisis (Copernicus Climate Data Store: ERA5 post-processed daily statistics on single [and pressure] levels from 1940 to present) considerados en la cuadrícula de latitudes de $[-165, 0]$ en longitud y $[-15, 75]$ en latitud, para poder considerar las teleconexiones que dominan el escenario climático guatemalteco, sin considerar ruido proveniente de otras regiones climáticas lejos de Centroamérica:

- Temperatura Superficial del Mar (SST).
- Presión Superficial (SP).
- Humedad relativa y específica (r y q) a 500 hPa.

- Geopotencial (z) a 500 hPa.
- Velocidades zonal y meridional (u, v) a 850 hPa.
- Índices de Madden-Julian Oscillation (RMM1, RMM2).

4.2.2 Normalización espacio-temporal

Todos los archivos de entrada (NetCDF4) fueron procesados para garantizar consistencia dimensional y nomenclatura:

- **Dimensiones:** Se normalizó la nomenclatura de ejes a `(time, lat, lon)`, independientemente del esquema original del archivo (`T`, `valid_time`, `time_counter`, etc.).
- **Coordenadas:** Se identificaron automáticamente los nombres de latitud y longitud (`latitude`, `y`, `Y`) y se renombraron a `lat` y `lon`.
- **Indexación temporal:** Se convirtieron valores numéricos o cadenas de tiempo a formato `datetime64` de NumPy para facilitar operaciones de fecha y sincronización.

4.2.3 Detección de píxeles válidos y máscaras espaciales

Dado que las grillas rasterizadas típicamente contienen píxeles con NaN (océanos, regiones fuera de dominio), se construyó una máscara de validez mediante muestreo de los primeros 50 pasos temporales de cada predictor. Un píxel se clasificó como válido si presentaba al menos un valor finito en el intervalo muestreado. Esta máscara aseguró que:

- La red neuronal procesa solo píxeles con datos físicamente significativos.
- Se evita acumular gradientes en píxeles sin información.
- La compresión dimensional mediante PCA se realiza exclusivamente sobre píxeles válidos.

4.3 Normalización y reducción de dimensionalidad

4.3.1 Estandarización de predictores

Para que el optimizador por gradiente converja eficientemente, cada predictor fue estandarizado usando estadísticas (media μ_p y desviación estándar σ_p) calculadas sobre el conjunto de entrenamiento:

$$X_{\text{std}}^{(p)} = \frac{X^{(p)} - \mu_p}{\sigma_p} \tag{4.1}$$

donde p indexa cada uno de los n_{pred} predictores. Estas estadísticas se almacenaron en la metadata del entrenamiento para reproducibilidad y aplicación consistente en predicciones posteriores.

4.3.2 Análisis de Componentes Principales (PCA)

Como los predictores climáticos típicamente presentan elevada colinealidad espacial (continuidad suave de campos como temperatura y presión), se aplicó PCA para reducir la dimensionalidad:

1. Se calculó la matriz de covarianza de cada predictor estandarizado sobre el conjunto de entrenamiento en píxeles válidos.
2. Se seleccionaron las primeras k_p componentes principales que acumulaban al menos el 95% de la varianza explicada, siempre que fuera posible.
3. El modelo PCA se almacenó para transformación consistente durante predicción.

La reducción dimensional cumple varios objetivos:

- Disminuye el número de parámetros de la red neuronal, mitigando el sobreajuste.
- Comprime información correlacionada en componentes ortogonales.
- Acelera el cálculo durante entrenamiento y predicción.

4.4 Construcción y segmentación de secuencias temporales

4.4.1 Ventanas de entrada

Para la predicción de precipitación mensual, la red LSTM requiere una ventana de entrada de longitud fija L (por defecto, $L = 31$ días). Formalmente, si se predice la precipitación acumulada en el mes $[t_{\text{start}}, t_{\text{end}}]$, la secuencia de entrada comprende L días anteriores:

$$\mathbf{x}_{t-L:t} = [X_{t-L}, X_{t-L+1}, \ldots, X_{t-1}] \tag{4.2}$$

donde cada X_τ es un vector de características (predictores normalizados y comprimidos por PCA) para el día τ.

4.4.2 División cronológica del conjunto de datos

Para evaluar la capacidad de generalización del modelo sin contaminación temporal (data leakage), el conjunto de datos se dividió de manera cronológica en dos subconjuntos:

- **Entrenamiento:** Años iniciales (70-80% del período total). Utilizado para ajustar los pesos $\mathbf{W}$ y sesgos $\mathbf{b}$ de la red mediante retropropagación del error.
- **Validación:** Período intermedio (30-20%). Monitorea el desempeño fuera de muestra durante el entrenamiento, permitiendo la detención temprana (*early stopping*) para evitar sobreajuste.

Esta partición respeta la estructura temporal inherente a los datos climáticos, donde la dependencia estadística es más fuerte entre observaciones cercanas en tiempo.

4.5 Arquitectura del modelo LSTM multi-torre

4.5.1 Diseño de entrada y torres paralelas

El modelo multi-torre procesa cada predictor climático mediante una rama (torre) independiente de capas LSTM y capas totalmente conectadas, explotando la especificidad de cada variable:

1. **Torre p:** Recibe una secuencia de entrada $\mathbf{x}_{t-L:t}^{(p)} \in \mathbb{R}^{L \times d_p}$, donde d_p es la dimensión post-PCA del predictor p.
2. **Capas LSTM:** La secuencia temporal se procesa mediante una o más capas LSTM que capturan dependencias de largo alcance. Cada LSTM emite un estado oculto $\mathbf{h}_T^{(p)}$ al final de la ventana.
3. **Capas densas locales:** El estado final se procesa mediante capas totalmente conectadas para extraer características no lineales específicas del predictor.

4.5.2 Fusión de representaciones y decodificación espacial

Las salidas de todas las torres se concatenan:

$$\mathbf{z} = [\mathbf{z}^{(1)}, \mathbf{z}^{(2)}, \ldots, \mathbf{z}^{(n_{\text{pred}})}] \tag{4.3}$$

A continuación, se aplican varias técnicas de refinamiento espacial:

1. **Modulación por coordenadas:** Un módulo aprendible que ingiere las coordenadas geográficas (lat, lon) de cada píxel y genera factores de escala y desplazamiento (shift) para modular las predicciones. Esta técnica captura variabilidad geográfica implícita.
2. **Sesgo por píxel:** Se añade un sesgo aprendible específico de cada píxel, permitiendo que el modelo capture errores sistemáticos locales.

3. **Refinamiento espacial:** Un módulo convolucional (2D) que reconstruye temporalmente la grilla ($h_{\text{target}} \times w_{\text{target}}$) a partir de píxeles válidos, propaga información espacial mediante capas convolucionales (Conv2D + BatchNorm), y reextrae los píxeles tierra para corrección fina.

4.5.3 Transformación de objetivo

Debido a la distribución fuertemente asimétrica (sesgada) de la precipitación mensual, se aplicó una transformación invertible al objetivo antes del entrenamiento. Las opciones implementadas incluyen:

- **Log-transformación:** $y_{\text{trans}} = \log(y + 1)$, adecuada para datos con rango amplio.
- **Raíz cúbica:** $y_{\text{trans}} = y^{1/3}$, reduce el impacto de valores extremos manteniendo el orden.
- **Raíz cuarta:** $y_{\text{trans}} = y^{1/4}$, estabilización más fuerte.
- **Raíz cuadrada:** $y_{\text{trans}} = \sqrt{y}$, apropiada para datos con varianza proporcional a la media.
- **Estandarización:** $y_{\text{trans}} = \frac{y-\mu_y}{\sigma_y}$, para varianza homogénea.

El modelo LSTM entrenó en el espacio transformado, y las predicciones se invirtieron analíticamente para recuperar precipitación en milímetros.

4.6 Entrenamiento del modelo

4.6.1 Función de pérdida y optimizador

Se empleó el error cuadrático medio (MSE) como función de pérdida en el espacio transformado:

$$\mathcal{L} = \text{MSE}(y_{\text{trans}}, \hat{y}_{\text{trans}}) = \frac{1}{n} \sum_{i=1}^{n} (y_{\text{trans},i} - \hat{y}_{\text{trans},i})^2 \tag{4.4}$$

El modelo se optimizó usando Adam (Adaptive Moment Estimation) con un esquema de tasa de aprendizaje adaptativo: calentamiento lineal (warmup) durante los primeros pasos, seguido de decaimiento coseno con reinicios (cosine annealing with warm restarts). Este esquema equilibra convergencia rápida inicial con refinamiento fino tardío.

4.6.2 Regularización y detención temprana

Para mitigar sobreajuste en esta red profunda se aplicaron:

1. **Dropout:** Se desactivó aleatoriamente un porcentaje (típicamente 20-30%) de neuronas en cada paso durante entrenamiento, forzando redundancia y robustez.
2. **Batch Normalization:** Se normalizaron las activaciones por minilote, acelerando convergencia y mejorando generalización.
3. **Early Stopping:** El entrenamiento se detuvo cuando la métrica de validación (RMSE o KGE) no mejoró durante N épocas consecutivas (típicamente $N = 15$), previniendo descenso en generalización.

4.6.3 Acumulación de gradientes

Para facilitar el entrenamiento con lotes grandes (que mejora estabilidad del gradiente), se implementó acumulación de gradientes: cada paso acumula gradientes de múltiples minilotes (típicamente 4-8) antes de actualizar pesos. Esto efectivamente incrementa el tamaño de lote sin aumentar uso de memoria GPU.

4.7 Evaluación del modelo

4.7.1 Métricas de error global

El desempeño predictivo se cuantificó mediante:

1. RMSE (Raíz del error cuadrático medio).
2. MAE (Error Absoluto Medio).
3. Coeficiente de Determinación (R^2).
4. Correlación de Pearson (r).

4.7.2 Métricas de eficiencia de modelos hidrológicos

Se incluyeron métricas estándar en predicción de precipitación:

1. Nash-Sutcliffe Efficiency (NSE).
2. Kling-Gupta Efficiency (KGE).
3. Porcentaje de Sesgo (PBIAS):

$$\text{PBIAS} = 100 \cdot \frac{\sum(\hat{y}_i - y_i)}{\sum y_i} \tag{4.5}$$

   Cuantifica si el modelo tiende a subestimar o sobrestimar la precipitación.

4.7.3 Análisis temporal y espacial

Para diagnosticar fortalezas y debilidades del modelo:

1. **Variación mensual:** Se calcularon RMSE, bias, correlación y KGE para cada mes del año, identificando estaciones de mejor/peor desempeño.
2. **Variación interanual:** Métricas agregadas por año hidrológico permiten detectar épocas de reducida habilidad predictiva (ej. bajo impacto de ENSO).
3. **Análisis de extremos:** Se evaluó desempeño específicamente en percentiles altos (P90, P95, P99) de precipitación, críticos para alerta temprana.
4. **Mapas espaciales:** Se generaron grillas de bias, RMSE, correlación, NSE y KGE píxel a píxel, revelando heterogeneidad geográfica del error.

4.7.4 Distribuciones y estadísticas de entrenamiento

Con el propósito de complementar, se consideró lo siguiente:

1. **QQ-plot:** Gráfico de cuantiles observados vs predichos, que expone desviaciones sistemáticas en colas.
2. **Función de distribución acumulada (CDF):** Comparación de CDFs observada y predicha, útil para verificar sesgo en percentiles.
3. **Percentiles cruzados:** Tabla de P10, P25, P50, P75, P90, P95 observados vs predichos, con razones que diagnostican compresión o dilatación de rango.

4.8 Diagnósticos ejecutados

Se desarrolló un programa de diagnósticos exhaustivos (`DIAGNÓSTICOS.py`) generando figuras y reportes estadísticos completos. Entre los diagnósticos clave se encuentran:

- Dispersión (hexbin + scatter con regresión lineal) de predicciones vs observaciones.
- Mapas espaciales de bias medio, RMSE, y correlación por píxel.
- Series temporales agregadas (promedio espacial) con intervalos intercuartílicos.
- Ciclo anual (promedio mensual climatológico).
- Métricas mensuales y anuales en tabla y gráficos.
- Análisis de extremos (percentiles altos).

- QQ-plot y función de distribución acumulada.
- Mapas de eficiencia (NSE, KGE) por píxel.
- Evolución temporal del error (RMSE y bias por paso temporal).

Los resultados se exportan tanto a figuras PNG (si se especifica `--save`) como a un archivo NetCDF con métricas espaciales (`*_diagnosticos.nc`) para análisis posterior.

4.9 Procedimiento de Predicción operativa

Una vez entrenado y validado un modelo, se utiliza en modo predicción mediante el script `PRONÓSTICO.py`. El procedimiento es:

1. **Cargar metadatos:** Se leen los parámetros de entrenamiento (normalización, PCA, transformación objetivo, etc.) desde `metadata.json` y modelos PCA desde cache.
2. **Validar predictores:** Se verifican que los archivos NetCDF nuevos posean la misma grilla, dimensionalidad y cobertura temporal que los datos de entrenamiento.
3. **Procesar ventanas:** Para cada mes objetivo, se extrae una ventana de L días previos, se normaliza, se aplica PCA, y se forma el tensor de entrada.
4. **Predicción:** El modelo LSTM infiere sobre las secuencias procesadas, generando valores en espacio transformado.
5. **Inversión y clipping:** Las predicciones se transforman inversamente a milímetros, se clipean a rangos físicos plausibles, y se reconstruye la grilla 2D.
6. **Exportación:** El resultado se guarda en formato NetCDF4 con metadatos descriptivos.

4.10 Procesamiento geográfico de resultados

Para análisis geográficos específicos (ej. desempeño en un departamento o región específica, mediante el paquete gtMapTools que incluye los shapes específicos del país utilizados en los análisis de INSIVUMEH), se implementó el script `DEP.py`, que:

1. Carga un archivo de predicciones NetCDF (típicamente `modelo_pixel_predictions.nc`).
2. Utiliza un shapefile de departamentos de Guatemala para definir polígonos.
3. Construye una máscara espacial (píxel dentro/fuera del polígono) usando geometría computacional.

4. Aplica la máscara a todas las timesteps de predicciones y observaciones.

5. Exporta un NetCDF recortado conservando la dimensión temporal completa.

Este tipo de recorte geográfico es útil para validación regional y para productos operativos específicos de una zona. Por ejemplo, para propósitos de este documento, se considera el shape asociado a Bocacosta y se realizan los diagnósticos de acuerdo a las variables de esa región.

Capítulo 5

Resultados

Capítulo 6

Conclusiones

Capítulo 7

Recomendaciones

Bibliografía

[1] Damián Jorge Matich. Redes neuronales: Conceptos básicos y aplicaciones. *Universidad Tecnológica Nacional, México*, 41:12–16, 2001.

[2] Rodrigo Salas. Redes neuronales artificiales. *Universidad de Valparaıso. Departamento de Computación*, 1(1):1–7, 2004.

[3] Claudio Javier Tablada and Germán Ariel Torres. Redes neuronales artificiales. *Revista de educación matemática*, 24(3), 2009.

[4] Fernando Izaurieta and Carlos Saavedra. Redes neuronales artificiales. *Departamento de Física, Universidad de Concepción Chile*, 2000.

[5] Warren S. McCulloch and Walter Pitts. A logical calculus of the ideas immanent in nervous activity. *Bulletin of Mathematical Biophysics*, 5:115–133, 1943.

[6] Masoud Hessami, Philippe Gachon, Taha B.M.J. Ouarda, and André St-Hilaire. Automated regression-based statistical downscaling tool. *Environmental Modelling Software*, 23(6):813–834, 2008.

[7] Mohammad Taghi Sattari, Anca Avram, Halit Apaydin, and Oliviu Matei. Evaluation of feature selection methods in estimation of precipitation based on deep learning artificial neural networks. *Water Resources Management*, 37(15):5871–5891, 2023.

[8] Pablo Rozas Larraondo, Luigi J. Renzullo, Inaki Inza, and Jose A. Lozano. A data-driven approach to precipitation parameterizations using convolutional encoder-decoder neural networks, 2019.

[9] Dry adiabatic lapse rate. `https://www.tpub.com/weather3/7.htm`, n.d. Archived from the original on 2016-06-03.

[10] L. D. Landau and E. M. Lifshitz. *Fluid Mechanics*, volume 6 of *Course of Theoretical Physics*. Butterworth-Heinemann, Oxford, 1987.

[11] Todd S Glickman. *Glossary of meteorology*. American Meteorological Soc., 2000.

[12] Richard P. Feynman. Illustrations of thermodynamics. In *The Feynman Lectures on Physics, Vol. I.* California Institute of Technology, Pasadena, CA, 1963.

[13] Alfred Brian Pippard. *Elements of classical thermodynamics: for advanced students of physics*. Cambridge University Press, 1964.

[14] Alexei V. Korolev and Ilia P. Mazin. Supersaturation of water vapor in clouds. *Journal of the Atmospheric Sciences*, 60(24):2957 – 2974, 2003.

[15] John F. Kolen and Stefan C. Kremer. *Gradient Flow in Recurrent Nets: The Difficulty of Learning LongTerm Dependencies*, pages 237–243. 2001.

[16] Soonchan Park and Heechan Han. Application of lstm and climate index for prediction of meteorological drought in south korea. *Water*, 17(12), 2025.

[17] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56):1929–1958, 2014.

[18] Federico Girosi, Michael Jones, and Tomaso Poggio. Regularization theory and neural networks architectures. *Neural Computation*, 7(2):219–269, 03 1995.

[19] Larry R Medsker, Lakhmi Jain, et al. Recurrent neural networks. *Design and applications*, 5(64-67):2, 2001.

[20] Mohaiminul Islam, Guorong Chen, and Shangzhu Jin. An overview of neural network. *American Journal of Neural Networks and Applications*, 5(1):7–11, 2019.

[21] Sepp Hochreiter. Recurrent neural net learning and vanishing gradient. *International Journal Of Uncertainity, Fuzziness and Knowledge-Based Systems*, 6(2):107–116, 1998.

[22] Juan Antonio Pérez Ortiz. Modelos predictivos basados en redes neuronales recurrentes de tiempo discreto. *Universidad de Alicante. Departamento de lenguaje y sistemas informáticos.[Documento en lınea http://www. conicyt. cIl573 Modelos predictivos basados en redes neuronales recurrentes de tiempo discreto. pdf][22/07/08]*, 2002.

[23] Stephen Grossberg. Recurrent neural networks. *Scholarpedia*, 8(2):1888, 2013.

[24] Yong Yu, Xiaosheng Si, Changhua Hu, and Jianxun Zhang. A review of recurrent neural networks: Lstm cells and network architectures. *Neural computation*, 31(7):1235–1270, 2019.

[25] Xuanyi Song, Yuetian Liu, Liang Xue, Jun Wang, Jingzhe Zhang, Junqiang Wang, Long Jiang, and Ziyan Cheng. Time-series well performance prediction based on long short-term memory (lstm) neural network model. *Journal of Petroleum Science and Engineering*, 186:106682, 2020.

[26] Zahra Karevan and Johan AK Suykens. Transductive lstm for time-series prediction: An application to weather forecasting. *Neural Networks*, 125:1–9, 2020.

[27] Russ Rew and Glenn Davis. Netcdf: an interface for scientific data access. *IEEE computer graphics and applications*, 10(4):76–82, 1990.

[28] Lars Peter Riishojgaard, John W Zillman, Adrian Simmons, and John Eyre. Intercambio de datos en la organización meteorológica mundial: contexto, historia e impacto. 2021.

[29] The HDF Group. Hdf5, 2024. Accessed: 2024-12-19.